

第一章 绪论

第二章 相关理论与技术

第三章 基于反事实输入的大语言模型偏见识别方法



偏见识别方法

敏感属性提取与统一表征

显示属性识别

隐式属性识别

统一四元组表示

反事实提示词构造

替换规则设计

反事实输入集合

语言自然性筛选

多维差异检测

语义偏移度

态度变化度

生成偏好差异

二阶段验证与最终判定

差异命题抽取

CoT反思验证

风险分数融合

第四章 基于反事实输入的大语言模型偏见识别方法



偏见重写方法

偏见片段定位

候选片段划分

候选片段偏见分数计算

片段定位结果

重写优先级排序

编辑代价设计

重写优先级计算

优先级排序

最小编辑重写

重写回复评分

代价与内容约束

局部定向重写

迭代循环

第五章 实验设计与结果分析



实验设置

数据集与样本构造
运行环节与流程

性能评估

第一部分： 偏见识别实验

情感差值

毒性差值

外部评审

第二部分： 偏见重写实验

语义保持度

校正效率

偏见去除率

结论