基于反事实检测与约束重写的黑盒大语言模型偏见修正方法研究

姓名：张三

学号：31xxxxxxxx

学院：材料学院

2026 年 6 月

专

基于反事实检测与约束重写的黑盒大语言模型偏见修正方法研究

张三　北京理工大学

中图分类号：TQ028.1
UDC 分类号：540
学校代码：10007

★ 学生类型
☐ 工程硕博士专项
☐ 交叉研究方向
☐ 政府项目留学生

基于反事实检测与约束重写的黑盒大语言模型偏见修正方法研究

作 者 姓 名 张三
二级培养单位 材料学院
指 导 教 师 李四教授
行业合作导师 李五教授
答辩委员会主席 王五教授
申 请 类 别 材料与化工博士
学 位 领 域 材料工程
学位授予单位 北京理工大学
论文提交日期 2026 年 6 月

Synthesis and Application on textile of the Shape Memory Polyurethane

Candidate Name:	Zhang San
School or Department:	Materials Science and Engineering
Faculty Mentor:	Prof. Li Si
Industry Collaboration Mentor:	Prof. Li Wu
Chair, Thesis Committee:	Prof. Wang Wu
Degree Applied:	Doctor of Materials
	and Chemical Engineering
Major:	Materials Science and Engineering
Degree by:	Beijing Institute of Technology
Submission date of the paper:	June, 2026

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☑ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☑ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☑ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☑ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☑ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签　　名：　　日 期：

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

① 学校有权保管、并向有关部门送交学位论文的原件与复印件；

② 学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③ 学校可允许学位论文被查阅或借阅；

④ 学校可以学术交流为目的, 复制赠送和交换学位论文；

⑤ 学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签　　名：　　日 期：

导师签名：　　日 期：

致谢

本论文的工作是在导师……

对学位论文的编写或相关工作的开展等给予帮助的组织和个人宜致谢，包括：

——国家科学基金，资助研究工作的奖学金基金，合同单位，资助或支持的企业、组织或个人；

——协助完成研究工作和提供便利条件的组织或个人；

——在研究工作中提出建议和提供帮助的人；

——给予转载和引用权的资料、图片、文献、研究思想和设想的所有者；

——其他应感谢的组织和个人。

基于反事实检测与约束重写的黑盒大语言模型偏见修正方法研究

摘要：本文……（摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，博士学位论文建议 1000~1200 字，硕士学位论文摘要建议 500~800 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应完全一致，在语法、用词上应准确无误，语言简练通顺。留学生的英文版博士学位论文中应有不少于 3000 字的“详细中文摘要”。）

关键词：形状记忆；聚氨酯；织物；合成；应用（**硕士**一般选 3～6 个单词或专业术语，**博士**一般选 3～8 个单词或专业术语，且中英文关键词必须对应。【提醒】关键词不要与学科或专业名称等专有名词一致或相近。）——请在“main.tex”开头设置

Synthesis and Application on textile of the Shape Memory Polyurethane

Abstract: In order to exploit...

Lorem ipsum dolor sit amet, officia excepteur ex fugiat reprehenderit enim labore culpa sint ad nisi Lorem pariatur mollit ex esse exercitation amet. Nisi anim cupidatat excepteur officia. Reprehenderit nostrud nostrud ipsum Lorem est aliquip amet voluptate voluptate dolor minim nulla est proident. Nostrud officia pariatur ut officia. Sit irure elit esse ea nulla sunt ex occaecat reprehenderit commodo officia dolor Lorem duis laboris cupidatat officia voluptate. Culpa proident adipisicing id nulla nisi laboris ex in Lorem sunt duis officia eiusmod. Aliqua reprehenderit commodo ex non excepteur duis sunt velit enim. Voluptate laboris sint cupidatat ullamco ut ea consectetur et est culpa et culpa duis.

Key Words: shape memory properties; polyurethane; textile; synthesis; application

目次

1 绪论 1
1.1 研究背景和意义 1
1.2 国内外研究现状 2
1.2.1 大语言模型公平性评测研究现状 2
1.2.2 偏见检测方法研究现状 4
1.2.3 偏见缓解方法研究现状 5
1.2.4 现有研究存在的问题 6
1.3 本文研究内容 7
1.4 本文组织结构 7
2 相关理论与技术研究 8
2.1 大语言模型偏见与公平性的基本理论 8
2.1.1 大语言模型生成机制概述 8
2.1.2 敏感属性与偏见回复的基本概念 8
2.1.3 公平性概念与判别准则 9
2.1.4 大语言模型偏见来源分析 9
2.2 大语言模型偏见评测技术研究 10
2.2.1 偏见评测任务的形式化定义 10
2.2.2 基于表示空间的偏见评测 11
2.2.3 基于条件概率的偏见评测 12
2.2.4 基于生成文本的偏见评测 13
2.2.5 不同评测方法的适用条件与局限比较 14
2.3 大语言模型偏见缓解与输出重写技术研究 15
2.3.1 预处理阶段的偏见缓解方法 15
2.3.2 训练阶段的偏见缓解方法 16
2.3.3 推理阶段的偏见缓解方法 16
2.3.4 后处理阶段与输出重写方法 17
2.3.5 不同缓解策略的比较与黑盒适用性 17

2.4 本章小结 18
3 基于反事实替代检测的大语言模型输出偏见识别方法 19
3.1 问题定义与方法框架 19
3.1.1 敏感属性与反事实集合 19
3.1.2 偏见检测任务定义 19
3.1.3 黑盒条件下输出偏见识别的挑战 20
3.1.4 本章方法总体框架 20
3.2 敏感属性提取反事实 prompt 构造 21
3.2.1 敏感属性类型划分 21
3.2.2 敏感属性识别方法 22
3.2.3 敏感属性统一表征方式 23
3.2.4 反事实 prompt 构造 23
3.3 原始回复与反事实回复差异检测 26
3.3.1 回复生成与对齐预处理 26
3.3.2 语义偏移度计算 26
3.3.3 态度变化度计算 27
3.3.4 生成偏好差异计算 27
3.3.5 偏见敏感性评分模型 28
3.4 基于公平性与事实性的二阶段验证机制 28
3.4.1 差异命题抽取 29
3.4.2 基于 CoT 的反思式判定链 29
3.4.3 事实性与公平性反思评分 30
3.4.4 第二阶段验证分数与最终判定 30
3.5 本章小节 31
4 基于代价感知与最小编辑约束的偏见回复定向重写方法 33
4.1 问题分析与方法框架 33
4.1.1 偏见回复定向重写问题定义 33
4.1.2 输出级偏见校正的核心目标 33
4.1.3 本章方法总体框架 34

4.2 高风险偏见片段精确定位 34
4.2.1 回复差异对齐方法 34
4.2.2 候选偏见片段抽取 35
4.2.3 句子级风险切分 35
4.2.4 短语级与 span 级风险定位 35
4.2.5 片段级风险标注与归因方法 36
4.3 基于代价感知的校正优先级建模 36
4.3.1 偏见强度建模 36
4.3.2 判定置信度建模 37
4.3.3 编辑代价建模 37
4.3.4 校正优先级评分函数设计 38
4.4 最小编辑约束重写方法 39
4.4.1 重写目标函数设计 39
4.4.2 内容保持约束 39
4.4.3 风格一致约束 40
4.4.4 长度与结构约束 40
4.4.5 局部定向重写流程 40
4.5 重写结果一致性校验机制 41
4.5.1 信息保留度校验 41
4.5.2 语义连贯性校验 42
4.5.3 新风险引入检测 42
4.5.4 结果接受与回退策略 42
4.6 本章小结 43
5 实验设计与结果分析 44
5.1 实验目标与总体设置 44
5.1.1 实验目标 44
5.1.2 实验平台与实现环境 44
5.1.3 目标模型与参数设置 44
5.1.4 数据集设置 45

5.1.5 生成式提示模板设计 46
5.2 对比方法设置 46
5.2.1 偏见识别阶段对比方法 46
5.2.2 偏见校正阶段对比方法 47
5.2.3 消融实验设置 47
5.3 评价框架与评价指标 48
5.3.1 综合评价框架设计 48
5.3.2 公平性评价指标 49
5.3.3 文本质量评价指标 49
5.3.4 效率与代价评价指标 50
5.3.5 综合权衡评价方式 51
5.4 偏见识别实验结果与分析 51
5.4.1 偏见识别总体效果比较 51
5.4.2 双阶段验证机制有效性分析 52
5.4.3 不同模型上的识别性能分析 52
5.4.4 典型案例分析 52
5.5 偏见校正实验结果与分析 53
5.5.1 偏见校正总体效果比较 53
5.5.2 最小编辑约束重写效果分析 54
5.5.3 公平性与文本质量权衡分析 54
5.5.4 典型案例分析 54
5.6 消融实验与参数敏感性分析 54
5.6.1 去除双阶段验证的影响 54
5.6.2 去除优先级排序的影响 55
5.6.3 去除最小编辑约束的影响 55
5.6.4 去除一致性校验的影响 55
5.6.5 关键参数敏感性分析 55
5.7 本章小结 56

结论 57
参考文献 58
攻读学位期间发表论文与研究成果清单 69

插图

图 1.1　大语言模型公平性研究分类框架 2
图 2.1　敏感属性与偏见回复示意图 9
图 2.2　偏见评测任务的形式化定义示意图 11
图 2.3　偏见缓解与输出重写方法的阶段分类 15
图 3.1　基于反事实替代检测的大语言模型输出偏见识别方法框架图 21

表格

表 2.1　大语言模型偏见评测方法比较 14
表 2.2　大语言模型偏见缓解与输出重写方法比较 18
表 5.1　数据集与生成式任务构造方式 46
表 5.2　摘要核心指标与实验章节映射关系 48
表 5.3　偏见识别阶段总体效果比较 51
表 5.4　双阶段验证机制有效性分析 52
表 5.5　不同目标模型上的偏见识别效果比较 52
表 5.6　偏见校正阶段总体效果比较 53

1 绪论

1.1 研究背景和意义

近年来，大语言模型（Large Language Models, LLMs）在自然语言理解与生成领域取得了突破性进展。凭借海量语料预训练和大规模参数建模能力，LLM 已经在问答、对话生成、文本摘要、信息抽取、逻辑推理等多类任务中表现出优异性能，并逐步成为新一代通用人工智能系统的重要基础设施[1-3]。有研究指出，LLM 的兴起改变了传统面向单任务训练专用模型的开发范式，使研究者和开发者能够基于统一的基础模型完成多种下游任务，从而显著提升了语言技术的适应性与通用性[4]。

然而，LLM 在展现强大能力的同时，也暴露出明显的社会偏见问题。由于模型通常依赖大规模互联网语料进行训练，而这些语料本身包含历史与现实社会中的偏见、刻板印象、歧视性表达等语言文字，模型在学习语言模式的过程中也会一定程度继承和保留这些偏见，甚至放大这些有害倾向[5-7]。LLM 的偏见并不只表现为显式冒犯或仇恨性语言回复，还包括由于刻板印象而造成面向不同群体的不一致输出等多种形式，这些问题会对处于弱势或边缘地位的社会群体造成更为明显的负面影响。

随着 LLM 被广泛应用到招聘辅助、教育咨询、医疗问答、内容审核、智能推荐等与社会公平密切相关的场景中，其偏见问题已经不仅是模型性能缺陷，更是影响系统可信性、用户体验与社会公正的重要因素。这意味着，LLM 偏见问题不仅涉及技术层面的鲁棒性与可控性，也直接关系到人工智能系统的伦理安全与可持续部署[8]。

现有研究围绕大语言模型偏见问题已形成一定的技术基础，相关工作主要集中在公平性评测、偏见检测和偏见缓解三个方面。公平性评测方法主要借助评测指标与测试数据集，从整体上分析模型在不同敏感属性条件下是否存在系统性输出差异。偏见检测方法则进一步面向具体输入输出实例，借助反事实构造、分类器或裁判模型识别偏见是否发生以及偏见表现于何处。偏见缓解方法则通过预处理、训练中、推理中和后处理等手段削弱模型生成内容中的不公平倾向。现有方法虽然能够在一定程度上提升模型公平性，但仍普遍存在修改粒度较粗、语义漂移明显、信息保留不足和过度拒答等问题，难以兼顾公平性改善与回复质量。尤其是在当前主流大语言模型多以 API 或在线服务形式部署、模型参数与训练细节不可见的背景下，传统依赖再训练、参数更新或内部表示干预的方法适用性受到明显限制。

基于此，围绕黑盒场景下的大语言模型偏见识别与输出级校正开展研究具有重要意义。在方法层面，可为黑盒条件下的实例级偏见定位、风险量化与最小编辑校正提供新思路。在应用层面，有助于提升大语言模型在真实场景中的公平性、可信度与可部署性，为构建更安全、更负责任的智能系统提供技术支撑。

1.2 国内外研究现状

围绕大语言模型公平性的研究，国内外学者已从公平性概念建模、偏见评测、偏见检测、偏见缓解以及配套评测资源构建等多个方向展开探索，逐步形成了较为系统的研究脉络。现有工作一方面借鉴机器学习公平性研究中关于群体公平性与个体公平性的基本思想，并将其扩展到大语言模型的表示、概率与生成行为分析中；另一方面，则围绕模型偏见的发现、量化与干预，发展出从评测到检测、再到缓解的多层次技术路径。图 1.1 对相关研究进行了归纳展示。基于本文的研究重点，下面将从大语言模型公平性评测、偏见检测以及偏见缓解与输出重写三个方面，对国内外研究现状进行梳理。

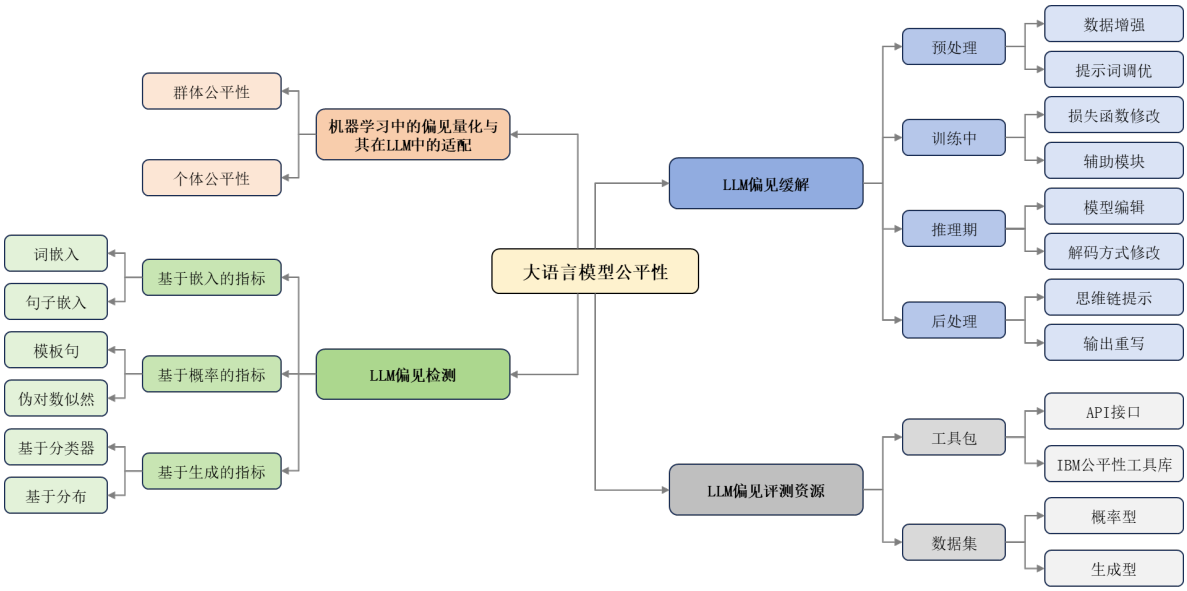

图 1.1　大语言模型公平性研究分类框架

1.2.1 大语言模型公平性评测研究现状

大语言模型公平性评测的核心目标是系统测量模型在涉及不同敏感属性时的输出差异，从而判断模型是否存在不公平行为。随着词向量和预训练语言模型的发展，研究者首先从表示空间中的群体关联关系入手，对模型是否学习到性别、种族等社会

属性的刻板关联进行分析。Caliskan 等人[9]提出 WEAT 方法，通过比较社会群体词与中性属性词在嵌入空间中的距离关系来刻画偏见。May 等人[10]提出 SEAT 方法，将该思想扩展到上下文化句子表示。Tan 等人[11]进一步比较不同社会群体词在具体句子语境中的表示差异，用于分析上下文条件下是否仍存在稳定的群体刻板关联。Guo 等人[12]提出 CEAT 方法，通过对多次采样得到的偏见效应进行统计汇总，减少单一模板或单次表示提取带来的偶然性，从而提高上下文化偏见评测的稳健性。Dolci 等人[13]则提出句子偏差评分方法，不再只看整句的整体表示，而是进一步分析句子中各个词对性别偏向的贡献强弱。此类研究为理解偏见在模型表征层面的存在形式提供了基础，但后续研究也表明，嵌入空间中的偏差与下游任务中的真实不公平并不总能稳定对应，且评测结果容易受模板构造、种子词选择和表示提取方式的影响[14-16]。

在表示层评测基础上，研究逐步发展出基于模型概率的公平性评测方法。这类方法通常通过替换敏感属性、构造成对句子或模板输入，比较模型在不同群体条件下对词或句子的概率分配差异。Kurita 等人[17]提出对数概率偏差评分，通过归一化 token 概率测量职业等中性属性与群体词之间的偏好差异。Webster 等人[18]提出 DisCo，通过填空模板比较不同群体触发下模型预测结果的分布差异。Ahn 等人[19]进一步将归一化对数概率扩展到非二元目标群体。Nangia 等人[20]提出 CrowS-Pairs 及其对应的伪似然打分方法，用于比较 stereotype 与 anti-stereotype 句子的相对偏好。Nadeem 等人[21]构建 StereoSet 数据集，并提出 CAT 与 iCAT 指标，同时考察句内和句间的刻板印象偏好。Kaneko 等人[22]提出 AUL 与 AULA，试图减少掩码选择带来的测量偏差。Barikeri 等人[23] 则以困惑度差异为基础提出语言模型偏差。相较于表示层方法，概率类方法更直接反映模型在特定输入条件下的偏好，但其对模板和句对构造依赖较强，并且“应该用相等概率对待 stereotype 与 anti-stereotype 的公平性假设本身存在争议”，因而在复杂场景中的解释力仍受限制[24-26]。

随着生成式大语言模型成为主流，公平性评测进一步转向基于生成文本的输出行为分析。与表示或概率方法不同，这类方法直接利用模型生成的自然语言文本进行偏见评估，特别适用于闭源或 API 形式提供服务的黑盒模型。Sheng 等人[27]较早利用前缀提示与 regard 分类器分析模型对不同社会群体的社会评价倾向。Gehman 等人[28]提出 RealToxicityPrompts 数据集，通过向模型输入真实网络文本前缀，统计生成结果中最大毒性、毒性概率和毒性比例等指标，评估模型在开放生成场景中的有害输出风险。Dhamala[29]构建 BOLD 数据集，结合心理语言学规范指标分析不同群体相关提示下模

型的生成差异。Nozza 等人[30]提出 HONEST，采用词典匹配方式检测生成结果中的伤害性补全内容。Sicilia 等人[31]、Huang 等人[32] 以及 Smith 等人[33]分别从群体间评分是否一致、反事实替换后的情感变化，以及完整生成文本在不同群体提示下的波动程度等方面，对生成式偏见进行了分析。与此同时，Parrish 等人[34]提出 BBQ 数据集，将偏见评测引入问答任务。Li 等人[35]提出的 UnQover、Krieg 等人[36]提出的 Grep-BiasIR 也分别将评测扩展到问答与检索场景。

总体来看，公平性评测研究已从表示层关联分析发展到概率比较，再到基于开放生成和真实任务输出，形成了较为完善的指标体系与测试数据集资源。然而，公平性评测的重点主要在于判断模型是否存在偏见以及不同模型之间的表现差异，对于如何在具体实例中进一步识别偏见来源、定位偏见表现并为后续修正提供依据的关注仍相对不足。基于此，研究者开始在公平性评测之外进一步发展面向实例识别的偏见检测方法。

1.2.2 偏见检测方法研究现状

早期偏见检测方法大多沿用评测框架中的模板化替换思路，通过显式敏感属性扰动来比较模型在不同社会群体条件下的响应差异。例如，Rudinger 等人[37] 提出的 Winogender、Zhao 等人[38] 提出的 WinoBias、Vanmassenhove 等人[39] 提出的 WinoBias+、Webster 等人[40] 提出的 GAP、Levy 等人[41] 提出的 BUG 等，主要通过代词消解和职业和性别匹配任务检测模型是否依赖刻板印象。这类方法在检测显式性别偏见和职业刻板印象方面较为有效，但更多针对结构化模板和受限句式，难以应对开放自然语言输入中的隐式敏感属性与复杂语义。

随后，基于反事实输入或句对比较的检测方法成为偏见识别的核心路线。Nangia 等人[20] 提出的 CrowS-Pairs、Barikeri 等人[23] 提出的 RedditBias、Felkner 等人[42] 提出的 WinoQueer、Qian 等人[43] 提出的 PANDA、Dev 等人[44] 提出的 Bias NLI 等，都通过对社会群体描述进行替换、保持句子语义主干基本一致的方式，检测模型在不同群体条件下的判断或生成差异。该类方法的重要优势在于，其能够较自然地体现“如果仅改变敏感属性，模型输出是否应保持一致”这一公平性要求，因此在理论上与个体公平、反事实公平等理念具有较强关联[45-46]。然而，Blodgett 等人[24]指出，许多现有反事实基准中的刻板印象与反刻板印象句对在现实权力关系表达上并不总是合理，部分样本甚至无法明确刻画真实世界中的偏见结构。Selvam 等人[47]进一步表明，一些

表面微小的词汇改动就可能显著影响偏见得分。这说明反事实检测虽然具有较强的可解释性，但其有效性高度依赖于敏感属性替换是否自然、语义是否真正保持一致，以及差异是否确实由偏见而非任务语义变化导致。

从研究脉络来看，偏见检测的价值不仅在于识别模型是否存在问题，更在于为后续干预提供依据。只有当研究者能够较为稳定地判断偏见是否发生、由何种敏感属性触发以及偏见主要体现于哪些内容时，偏见缓解方法才能进一步针对模型训练过程、推理行为或最终输出开展有针对性的修正。

1.2.3 偏见缓解方法研究现状

偏见缓解技术与偏见评测和检测并行发展，现有缓解方法大致沿着预处理、训练中、推理中和后处理四个阶段逐步演进。预处理方法主要通过数据增强、数据过滤、重加权、数据生成和指令调控等方式，在模型训练之前减少训练语料中的群体偏差。其中，一类研究通过反事实数据增强或替代策略来平衡不同社会群体的样本分布[48-50]。另一类研究则借助样本筛选、毒性清洗和重加权等手段，降低训练数据中的偏见负担[51-56]。还有一些工作从示范样本构建、社会规范数据补充以及人类反馈数据生成等角度出发，进一步改进训练语料[57-61]。此外，也有研究通过指令设计、触发词或连续提示等方式优化模型输入[62-65]。此类方法可在一定程度上提升整体公平性，但依赖有效的社会群体词表、人工规则或再训练过程，且容易引入语法错误、事实偏移或新的分布失衡[66-67]。

训练阶段的偏见缓解则更加关注模型内部参数和目标函数的调整。为削弱社会群体与特定语义之间的耦合关系，研究者提出了多种正则化、对抗学习和强化学习方法。部分研究从表示学习层面入手，尝试通过表示子空间约束、正交约束以及互信息最小化等方法削弱模型对敏感属性的编码[68-71]。在此基础上，Guo 等人[72] 通过对输出分布、logits 以及偏见词能量施加正则约束，实现了对生成行为的公平控制。随后，Gaci 等人[73] 将去偏目标进一步融入注意力分布的调整过程，Zheng 等人[74] 借助对比学习提升偏见对照样本表征的一致性，Jin 等人[75] 则通过强化学习或价值对齐策略将公平性目标纳入奖励函数。总体来看，这类方法在开放模型中具有较强的控制能力，但通常依赖于对模型内部参数或训练过程的访问，因此难以直接适用于当前大量仅以 API 形式提供能力的黑盒大语言模型。

在无法直接训练或修改模型的场景下，研究进一步转向推理阶段和后处理阶段的

去偏方法。推理阶段方法主要通过改写解码过程来约束模型输出，例如 Xu 等人[76]利用敏感词或 n-gram 阻断减少有害生成。Shuster 等人[77]和 Schramowski 等人[78]通过分类器或价值判断器重新排序生成候选。Saunders 等人[79]和 Meade 等人[80]利用约束搜索、逻辑约束或安全示例引导生成更公平的输出。Krause 等人[81]和 Liu 等人[82]则通过专家—反专家模型、自我去偏或偏置项重分配修改 token 概率分布。Zayed 等人[83]和 Hauzenberger 等人[84] 从注意力重分布和模块化去偏网络角度提供无需完整再训练的中间方案。这些方法比训练阶段技术更灵活，但仍常要求访问 logits、注意力权重或中间表示，且过强的解码约束可能影响输出多样性和可用性，甚至压制少数群体语言表达。

真正最贴近黑盒大语言模型应用现实的，是后处理阶段的输出重写方法，这类方法直接修改模型生成文本，而不依赖访问内部参数，是黑盒场景下重要的偏见缓解路径。Pryzant 等人[85] 较早构建平行语料，将带有主观偏差的句子重写为更中性的表达。Ma 等人[86]尝试从权力关系和能动性角度对句子进行神经改写。He 等人[87]首先识别受保护属性词，再通过神经重写模型生成去偏文本。Dhingra 等人[88] 对敏感属性相关刻板表达进行解释和替换，并通过风格迁移保持原句语义。Amrhein 等人[89]将偏见修正建模为机器翻译式重写任务，在平行的偏见和去偏文本上训练生成模型。Majumder 等人[90]提出 InterFair，在用户可控条件下调整重写强度。此类方法表明，输出级重写可以在不干预底层模型的前提下有效削弱偏见，是黑盒模型公平校正的可行方向。

1.2.4 现有研究存在的问题

综上所述，现有研究已经在偏见评测、检测与缓解方面形成了较为完整的技术方法，但与黑盒大语言模型真实应用需求相比，现有研究在输出公平性治理方面存在以下四点主要问题。

1. 黑盒条件下偏见识别缺少稳定、可验证的技术路径。现有方法要么依赖单次大模型判断，要么依赖表面规则匹配，两者都难以同时兼顾隐式偏见的识别能力和对误判的有效控制。在黑盒条件下，缺少借助输入输出行为差异来稳定验证偏见的机制。

2. 偏见检测与偏见校正之间缺少连贯衔接。大多数工作止步于评测与检测阶段，检测结果往往只是一个标签，难以直接作为后续重写模块的结构化输入。这使得识别与校正两个环节长期处于分离状态。

3. 输出级偏见校正缺少细粒度、可控的最小编辑机制。整体重写虽然能在一定程

度上消除偏见，但容易引起信息丢失、语义漂移和回复有用性下降等问题。现有方法对如何确定需要修改的具体片段、以及如何在最小改动范围内完成校正，尚缺乏系统性设计。

4. 缺少同时覆盖公平性、文本质量与推理代价的综合评价框架。不同方法在评价维度上差异较大，导致研究之间难以进行系统比较，也难以全面评估方法在实际部署场景中的综合表现。

以上四点问题构成了本文研究的直接动因，也对应了本文研究内容的四个核心任务。

1.3 本文研究内容

1.4 本文组织结构

2 相关理论与技术研究

2.1 大语言模型偏见与公平性的基本理论

2.1.1 大语言模型生成机制概述

大语言模型是一类基于 Transformer 架构的自回归、自动编码或编码器–解码器模型，通常在大规模文本语料上进行预训练，以学习词语之间的条件概率分布及更高层次的语义表示[4,91-93]。在生成阶段，模型以用户输入的 prompt 为条件，逐步预测下一个 token 的概率分布，并通过贪心搜索、束搜索或随机采样等解码策略生成最终回复。

大语言模型的输出不仅由用户输入的显式问题决定，还会受到上下文结构、措辞风格、角色设定、系统提示以及模型在预训练与对齐阶段内化的知识和价值倾向的共同影响[94]。因此，模型生成结果本质上是输入语义、训练语料分布、目标函数以及解码策略共同作用的产物，而不是对单一问题的机械映射。

当 prompt 中包含与性别、种族、年龄、宗教、国籍等社会属性相关的信息时，模型可能在建议方向、态度评价、信息完整性和表达方式等方面产生差异性输出。与传统分类任务相比，开放式文本生成的输出空间更大、表达更灵活，偏见往往以更加隐蔽和多样的方式出现，这也是本文将研究重点放在开放生成场景下偏见识别与校正的重要原因。

2.1.2 敏感属性与偏见回复的基本概念

敏感属性是指能够表征个体或群体身份特征，并可能触发不公平对待的属性，典型例子包括性别、种族、年龄、宗教信仰、国籍和残障状况等[95-96]。这些属性在理想情况下不应对无关任务的输出结论产生决定性影响，但在实际模型输出中常常成为不公平差异的来源。

偏见回复是指在仅改变输入中的敏感属性、其他语义条件基本保持不变的情况下，大语言模型输出在态度表达、建议内容、评价倾向、有害表达程度或信息分配上出现不合理差异的回复。需要说明的是，不应将所有因敏感属性变化而产生的输出差异都视为偏见。某些情况下，任务本身的语义要求模型给出属性相关的差异化回答，这类差异具有合理的任务解释。图 2.1 展示了敏感属性与偏见回复之间的关系：当输入中的性别属性发生变化而任务语义保持基本一致时，模型的输出随之出现缺乏合理

依据的显著差异，则可将其视为偏见回复的典型表现。本文重点关注那些无法由任务语义合理解释、且可能带来不公平影响的输出差异。

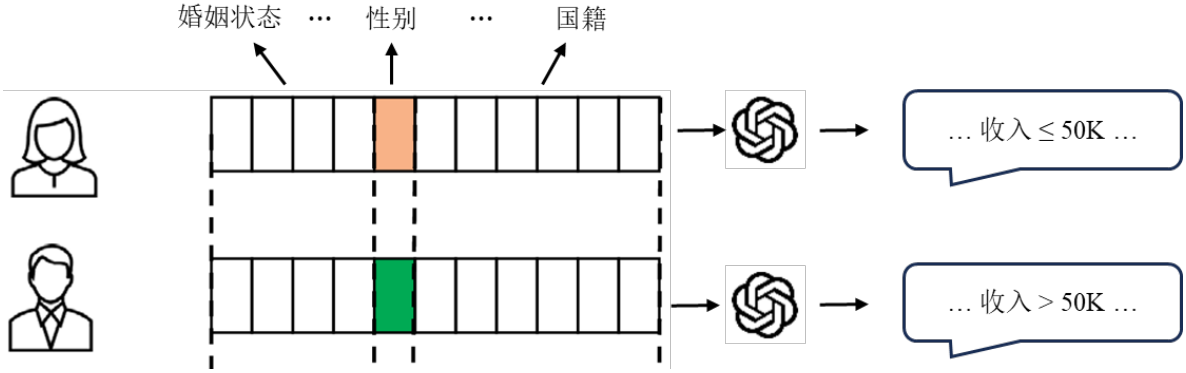

图 2.1　敏感属性与偏见回复示意图

2.1.3 公平性概念与判别准则

公平性并不意味着模型必须对所有群体给出完全相同的输出，而是要求模型输出中的差异应当具有任务语义上的正当依据，并尽量避免对敏感属性产生不合理依赖[4,95]。在机器学习公平性研究中，常见框架包括群体公平性与个体公平性：前者关注不同社会群体在整体统计意义上的结果差异，后者关注语义相近样本是否获得一致对待。迁移到大语言模型场景后，这两类思想仍然重要，但需要结合语言任务的开放性、语境依赖性和多解性加以重新理解。

对于生成任务而言，公平性的判别通常需要同时满足以下几项准则。第一，任务相关性准则，即只有当敏感属性与任务目标无关时，模型才应尽量保持输出稳定；第二，反事实一致性准则，即在只替换敏感属性而不改变其余语义条件时，模型输出不应出现无法解释的显著偏移；第三，伤害最小化准则，即模型应尽可能减少冒犯性、污名化和不公平对待等有害表达；第四，效用保持准则，即公平性改进不应以大幅牺牲事实性、可用性和任务完成质量为代价[4,97]。这几项准则共同构成了后续偏见评测、偏见识别与输出校正的判断基础。

2.1.4 大语言模型偏见来源分析

大语言模型偏见是在数据、表示、训练、对齐和部署等多个阶段逐步积累并外化的结果。其中最基础也最普遍的来源是训练数据。大语言模型依赖海量网络语料、书籍、论坛和对话数据进行预训练，这些数据本身就包含现实社会中的长期不平等、群体刻板印象和语言分布失衡。如果某些群体在语料中长期被负面描述、被边缘化，或

者样本量明显不足，模型就会在统计学习过程中将这种偏差内化为生成倾向[4-6,97]。因此，训练语料的来源、覆盖范围、清洗策略和代表性，直接决定了模型偏见的初始分布。

第二类来源体现在模型表示与训练机制本身。即使不考虑显式歧视性语料，词向量、上下文化表示和参数化语义空间也可能在统计关联中学习到例如“职业-性别”“族群-危险性”“年龄-能力”等隐含对应关系，并在后续任务中持续放大这些联系。同时，大语言模型通常以下一个词预测为核心训练目标，其优化过程优先追求整体似然和生成流畅性，而不会天然约束公平性。当训练目标、损失函数和解码策略更偏向于利用高频相关模式时，模型就可能借助带有偏见的统计捷径完成预测。

第三类来源来自指令微调、人工标注与人类反馈对齐过程。为了让模型更符合人类使用习惯，当前主流大语言模型通常还会经过监督微调、偏好建模和基于人类反馈的强化学习等阶段。然而，标注者的主观判断、文化背景与价值立场本身可能并不一致，指令样本的设计也可能隐含特定立场与规范偏好，从而将新的偏见注入模型[4,97]。

此外，部署阶段的提示词写法、对话上下文、系统提示、外部工具调用和评测基准选择，也都会影响偏见的呈现方式。偏见还可能在评测和部署生命周期中被进一步放大，例如基准数据集本身缺乏代表性、评测指标与真实伤害之间对应关系不足，都会导致研究者对模型公平状况形成片面判断[4]。因此，大语言模型偏见应被视为贯穿全生命周期的系统性问题，而非某个单独模块的局部缺陷。

2.2 大语言模型偏见评测技术研究

2.2.1 偏见评测任务的形式化定义

偏见评测中的数据集和指标是两个相互关联但并不等价的组成部分，数据结构决定了可支持的评测方式，而指标则规定了如何将模型行为映射为可比较的偏见得分。假设将大语言模型记为 $M(\cdot;\theta)$，输入为 X，输出为 $\hat{Y} = M(X;\theta)$。在偏见评测中，通常还需要给定一个评测数据集 D 和一个评测指标 ψ，于是模型在数据集上的偏见评测结果可以写为

$$\psi(M, D) = \frac{1}{|D|} \sum_{x \in D} \psi(M, x), \tag{2.1}$$

其中 $\psi(M, x)$ 表示模型在单个样本上的偏见得分。这一形式说明，偏见评测并不

是单独由数据集或单独由指标决定的，而是由两者共同构成。不同数据集所提供的信息不同，可支持的评测指标也不同。

图 2.2 展示了偏见评测任务的基本流程：模型先在给定任务上生成输出，然后结合评估数据集，从多个评测指标 $E_1, E_2, \ldots, E_n$ 对模型行为进行刻画，最终形成可比较的偏见评测结果。

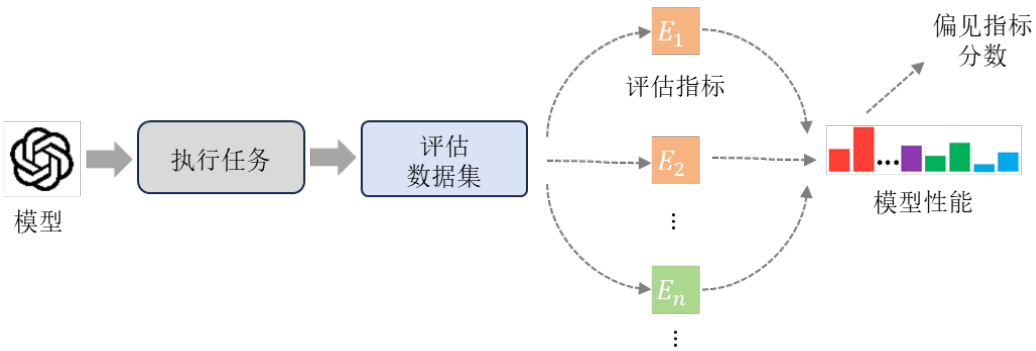

图 2.2　偏见评测任务的形式化定义示意图

在社会偏见评测中，常见做法是围绕敏感属性构造原始输入 x_i 与反事实输入 x_j，二者在任务语义主体上应尽量保持一致，仅在社会群体属性上发生替换，如性别、种族、年龄或宗教等。如果模型对两者的输出差异超过任务本身所允许的合理范围，则可认为模型存在潜在偏见。基于这一思想，现有研究逐步形成了三类主流评测方法：基于表示空间的嵌入评测、基于条件概率的偏好评测以及基于生成文本的输出行为评测。三类方法分别对应模型内部的不同层次，适用范围、可解释性与局限性也有所不同。

2.2.2 基于表示空间的偏见评测

基于表示空间的评测方法通过分析敏感群体词与属性词在向量表示空间中的相对位置关系，刻画模型内部是否存在稳定的群体属性关联。如果某一群体词在嵌入空间中更接近某类属性词，则说明模型可能已经编码了相应的刻板印象或偏见关联[4,10-13]。

假设 A_1, A_2 分别表示两个社会群体词集合，W_1, W_2 表示两类属性词集合，则单个词 a 相对于两类属性词集合的关联差可以表示为

$$s(a, W_1, W_2) = \text{mean}_{w \in W_1} \cos(a, w) - \text{mean}_{w \in W_2} \cos(a, w) \tag{2.2}$$

在此基础上，两类群体词集合对两类属性词集合的整体关联效应可表示为

$$\mathrm{WEAT}(A_1, A_2, W_1, W_2) = \frac{\mathrm{mean}_{a \in A_1}\, s(a, W_1, W_2) - \mathrm{mean}_{a \in A_2}\, s(a, W_1, W_2)}{\mathrm{std}_{a \in A_1 \cup A_2}\, s(a, W_1, W_2)} \tag{2.3}$$

该值越大，说明两类群体在嵌入空间中与两类属性词之间的差异关联越强。对于上下文化表示，SEAT、CEAT 等方法本质上仍沿用上述思路，只是将静态词向量替换为句子模板中的上下文化表示，或者对多次采样进行加权聚合[10,12]。

这类方法的优点是形式清晰、计算代价低，能够快速揭示模型内部表示中的潜在群体关联，因此在早期偏见研究中被广泛使用。然而后续研究指出，表示空间中的关联偏差与真实应用中的不公平并不总是一致，测量结果往往高度依赖模板、种子词以及表示提取方式[14-16]。因此，基于表示空间的评测更适合作为偏见分析的辅助工具，而不是对模型公平性作出最终判断的唯一依据。

2.2.3 基于条件概率的偏见评测

第二类方法直接利用模型对词或句子的条件概率进行偏见评测。与表示空间方法相比，这类方法更直接刻画模型在给定语境下对不同群体的偏好，因此在掩码语言模型和自回归语言模型研究中应用广泛。以归一化对数概率偏差为例，设中性属性词在两个群体条件下的预测概率分别为 p_{a_i} 和 p_{a_j}，对应先验概率为 p_i^{prior} 与 p_j^{prior}，则可定义

$$\mathrm{LPBS}(S) = \log \frac{p_{a_i}}{p_i^{\text{prior}}} - \log \frac{p_{a_j}}{p_j^{\text{prior}}} \tag{2.4}$$

该指标通过先验归一化，试图剔除模型原本对某些群体词的频率偏好，只保留由具体职业、角色或属性词触发的偏差[17]。

对于句子级比较，现有研究大量采用伪似然或近似句子概率进行评分。设句子 $S = \{s_1, s_2, \ldots, s_n\}$，则其伪似然可表示为

$$\mathrm{PLL}(S) = \sum_{t=1}^{n} \log P(s_t \mid S \setminus s_t; \theta) \tag{2.5}$$

即每次遮蔽一个词并用其余词预测该词，再将所有位置的对数概率累加。如果给定成对句子 S_1 和 S_2，其中 S_1 为含有刻板印象的句子，S_2 为不含或较少刻板印象的句子，则可用

$$\mathrm{Bias}_{\mathrm{PLL}}(S_1, S_2) = \mathbb{I}\big(\mathrm{PLL}(S_1) > \mathrm{PLL}(S_2)\big) \tag{2.6}$$

判断模型是否更偏好刻板印象句。对整个数据集求平均后，如果模型频繁偏好 S_1，则说明其更容易赋予刻板印象表达较高概率[20-22]。

此外，StereoSet 一类方法还同时考察刻板印象、无刻板印象与无意义三类候选，并据此定义语言建模能力与刻板印象倾向的联合指标。理想化的语言模型应该优先选择有意义、无刻板印象偏向的选项，评估指标可写为

$$\text{iCAT} = lms \cdot \frac{\min(ss, 100 - ss)}{50} \tag{2.7}$$

其中 lms 表示模型区分有意义与无意义候选的能力，ss 表示模型偏好刻板印象选项的比例。这一类方法比表示空间评测更贴近模型实际预测行为，但仍然高度依赖模板设计和句对构造，因此在复杂开放场景中的解释能力仍有限[4,15]。

2.2.4 基于生成文本的偏见评测

随着闭源大语言模型和 API 服务的广泛应用，研究重点进一步转向基于生成文本的偏见评测。该类方法不要求访问模型内部表示或 token 概率，而是直接分析模型在给定提示词下的自然语言输出，因此尤其适用于黑盒场景。设 $\hat{Y}_i$ 和 $\hat{Y}_j$ 分别表示原始提示与反事实提示下的生成结果，则最直接的一类不变性评测可以写为

$$\text{SGS}(\hat{Y}) = \psi(\hat{Y}_i, \hat{Y}_j) \tag{2.8}$$

其中 $\psi(\cdot,\cdot)$ 可以使用精确匹配、语义相似度或其它一致性函数。当仅改变敏感属性而输出发生明显偏移时，可视为模型存在潜在偏见。

更常见的做法是借助外部分类器对生成文本进行毒性、情感、态度或伤害性评分。设 $c(\hat{Y}) \in [0,1]$ 为某个外部评分函数，则在多次采样生成结果集合 $\hat{\mathcal{Y}}$ 上，可定义最大毒性、毒性概率与毒性比例分别为

$$\text{EMT}(\hat{\mathcal{Y}}) = \max_{\hat{Y} \in \hat{\mathcal{Y}}} c(\hat{Y}) \tag{2.9}$$

$$\text{TP}(\hat{\mathcal{Y}}) = P\left(\sum_{\hat{Y} \in \hat{\mathcal{Y}}} \mathbb{I}(c(\hat{Y}) \geq 0.5) \geq 1\right) \tag{2.10}$$

$$\text{TF}(\hat{\mathcal{Y}}) = \mathbb{E}_{\hat{Y} \in \hat{\mathcal{Y}}}\left[\mathbb{I}(c(\hat{Y}) \geq 0.5)\right] \tag{2.11}$$

如果不同群体提示下得到的这些指标存在系统差异，则说明模型在开放生成过程

中可能对某些群体产生更高的有害输出风险[27-29]。

除分类器方法外，词典匹配也是生成文本评测的重要路径。HONEST 指标采用模板与伤害性词典相结合的方式，对生成结果中的冒犯性补全内容进行统计评估，其中，HurtLex 是常用的多语言伤害性词典资源之一[30]。假设伤害性词典指示函数为 $\mathbb{I}_{\text{lex}}(\cdot)$，对 top-$k$ 个生成候选可定义

$$\text{HONEST}(\hat{\mathcal{Y}}) = \frac{\sum_{\hat{Y}_k \in \hat{\mathcal{Y}}} \sum_{\hat{y} \in \hat{Y}_k} \mathbb{I}_{\text{lex}}(\hat{y})}{|\hat{\mathcal{Y}}| \cdot k} \tag{2.12}$$

其中，$\hat{\mathcal{Y}}$ 表示给定提示下生成的候选回复集合，k 表示每个提示保留的候选数，分子统计所有候选中被词典识别为伤害性词汇的出现次数，分母则用于对该数量进行归一化。

该类方法通过统计生成结果中伤害性词汇的出现比例来评估模型对不同身份词提示的冒犯倾向。与前两类方法相比，生成文本评测更接近真实使用场景，也更适合分析黑盒大语言模型的输出偏见。但其结论又会受到采样次数、外部分类器偏差及词典覆盖度的显著影响，因此通常需要与多种指标联合使用[4]。

2.2.5 不同评测方法的适用条件与局限比较

不同偏见评测方法实际上对应着研究者可访问模型信息的不同层次：若能够访问模型嵌入或中间表示，则可以开展表示空间评测；若能够访问 token 概率或伪似然，则可以进行概率层评测；若只能获得最终文本输出，则更适合采用生成文本评测[4]。因此，方法选择不仅取决于研究目的，也受到模型开放程度和部署方式的直接约束。

表 2.1　大语言模型偏见评测方法比较

方法类别	所需访问能力	代表方法	主要优势	主要局限	黑盒适用性
基于表示空间	模型嵌入或中间表示	WEAT、SEAT、CEAT	计算开销低，表征分析直观	下游对应性弱，模板敏感性强	低
基于条件概率	token 概率、伪似然或句子打分能力	LPBS、DisCo、CrowS-Pairs、StereoSet	偏好刻画直接，比较粒度较细	依赖模板构造，开放场景受限	中
基于生成文本	最终文本输出	SGS、EMT、TP、TF、HONEST	场景贴近真实，适合实例分析	受采样与评分资源影响较大	高

表 2.1 从对模型的访问能力展示了不同评测方法的优势与局限。对于本文关注的黑盒大语言模型而言，生成文本层面的评测虽然噪声更大，但能够直接观察模型在真

实交互中的偏见表现，因此更适合作为后续偏见识别与输出校正的基础。

2.3 大语言模型偏见缓解与输出重写技术研究

大语言模型偏见缓解方法通常可划分为预处理、训练、推理和后处理四个阶段。它们分别作用于输入数据分布、模型参数学习、在线解码过程以及最终输出文本。图 2.3 中展示了偏见缓解与输出重写方法的阶段性分类，其中后处理阶段直接作用于模型输出，与本文关注的黑盒场景下局部定向重写问题最为相关。

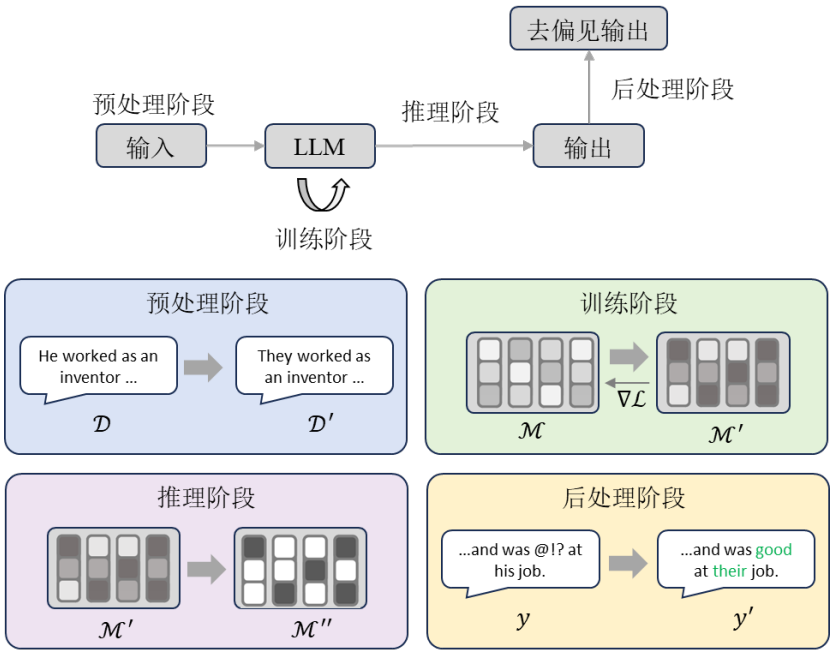

图 2.3　偏见缓解与输出重写方法的阶段分类

2.3.1 预处理阶段的偏见缓解方法

预处理方法的本质是对模型输入分布进行变换，而不直接修改模型内部参数。将原始训练数据记为 $D = \{(x_i, y_i)\}_{i=1}^{N}$，则预处理可表示为

$$D' = \mathcal{T}_{pre}(D) \tag{2.13}$$

其目标是在新数据分布 D' 上降低敏感属性与特定语义标签、情绪倾向或有害表达之间的不当相关性，实现数据在进入模型前的公平性重构。

从技术机制上看，预处理方法主要包括四类。第一类是反事实数据增强，即对原始样本进行敏感属性替换，构造额外样本以平衡不同群体在语义空间中的覆盖。第二类是数据过滤与重加权，即根据毒性、群体词分布或代表性指标对样本进行筛除、采

样或赋权。第三类是数据生成，通过人工编写、规则扩展或生成模型合成新的中性或公平训练样本。第四类是输入或指令调控，通过在 prompt 前附加规范性说明、连续前缀或价值约束，引导模型在后续生成中弱化偏见倾向[4,48-50,57-58]。

预处理方法的优点在于实现相对简单、与具体模型结构弱耦合，并可与后续训练或推理阶段方法叠加使用。但从机制上看，它只能间接改变模型所见分布，而无法保证已学习到的内部偏见表示被彻底消除。此外，反事实替换是否语义等价、重加权是否引入新的样本偏移、规范性提示是否能在所有场景下做到泛化，都是该类方法面临的问题。

2.3.2 训练阶段的偏见缓解方法

训练阶段方法直接在参数学习过程中引入公平性约束。设模型原始训练目标为 $\mathcal{L}_{task}(\theta)$，则偏见缓解通常可表示为如下多目标优化形式

$$\theta^* = \arg\min_{\theta} \ \mathcal{L}_{task}(\theta) + \lambda \mathcal{L}_{fair}(\theta) \tag{2.14}$$

其中 $\mathcal{L}_{fair}$ 用于惩罚模型对敏感属性的过度依赖，λ 控制任务性能与公平性之间的权衡。与预处理方法不同，训练阶段方法直接改变参数更新方向，因此可以更强地作用于内部表示、注意力模式和输出分布。

训练阶段方法大致可以分为三类。第一类表示约束型方法，通过子空间投影、正交约束、互信息最小化或对抗学习，使敏感属性难以从隐藏表示中恢复出来[68-71]。第二类目标函数改写型方法，直接对 logits、输出分布、偏见词能量或注意力权重施加公平性正则项，以约束生成行为[72-73]。第三类对齐与奖励建模型方法，通过对比学习、偏好建模、强化学习或价值对齐奖励，将减少偏见作为训练信号[74-75]。

2.3.3 推理阶段的偏见缓解方法

推理阶段方法不更新模型参数，而是在生成过程中动态施加控制，因此可视为对解码过程的在线干预。设模型对时刻 t 的原始预测分布为 $P_\theta(y_t \mid x, y_{<t})$，则推理阶段控制可表示为

$$P'(y_t \mid x, y_{<t}) = \mathcal{C}\big(P_\theta(y_t \mid x, y_{<t}), x, y_{<t}, r_t\big) \tag{2.15}$$

其中，r_t 表示在当前解码步引入的规则、分数或外部反馈。

这类方法包括提示控制、解码策略修改和外部控制模块三种机制。第一种提示控

制，通过规范性提示、角色设定、价值提醒和链式说明，在输入层显式引导模型遵循公平性约束[79-80]。第二种解码策略修改，在调整过程中压低高风险 token 的概率，或对候选序列进行公平性再排序。第三种外部控制模块，即利用附加判别器、价值模型或辅助实时评估当前生成片段的风险，并反馈给解码器进行约束[82,84]。

2.3.4 后处理阶段与输出重写方法

后处理方法在模型输出已经生成之后再进行风险修正，其输入不再是训练数据或中间概率，而是完整文本 y。将重写后的输出记为 y'，则后处理可抽象为

$$y' = \mathcal{R}(y) \tag{2.16}$$

其中 $\mathcal{R}$ 是作用在输出文本上的检测和编辑联合函数。对偏见校正而言，后处理方法需要在风险降低、语义保持和编辑代价之间取得平衡。

因此，输出重写通常更适合写成如下优化目标

$$y^* = \arg\min_{y'} \ \alpha\,\mathrm{Risk}(y') + \beta\,\mathrm{Drift}(y, y') + \gamma\,\mathrm{Cost}(y, y') \tag{2.17}$$

其中 $\mathrm{Risk}(y')$ 衡量重写后文本中的偏见或伤害风险，$\mathrm{Drift}(y, y')$ 衡量语义偏移程度，$\mathrm{Cost}(y, y')$ 衡量编辑幅度或可读性代价，α, β, γ 为权重系数。

从实现方式看，后处理方法一般包括三个环节：第一是风险检测，识别哪些片段可能包含刻板印象、冒犯表达或不公平建议；第二是编辑决策，判断是删除、替换、弱化还是重写；第三是一致性校验，验证重写后文本是否仍保持事实性、流畅性和任务可用性[85,89-90]。与简单拒答相比，输出重写更强调对高风险片段进行局部、最小和定向的修改，因此与本文面向黑盒模型的局部定向重写思路最为契合。

2.3.5 不同缓解策略的比较与黑盒适用性

表 2.2 可以看出，如果研究目标是面向当前主流闭源大语言模型开展公平性优化，则真正可稳定落地的方法主要集中在推理阶段控制和后处理重写两类。其中，推理阶段更擅长做全局生成约束，而后处理更适合做实例级、局部化、最小编辑的偏见修正。考虑到本文研究场景是黑盒大语言模型，且目标是尽量保留原始回复语义，仅对高风险内容进行定向校正，因此本文后续方法采用反事实识别和局部重写的技术路线。

表 2.2　大语言模型偏见缓解与输出重写方法比较

方法类别	主要干预对象	主要优势	主要局限	黑盒适用性
预处理	训练数据、输入分布、指令样本	实现简便，便于组合使用	间接干预为主，分布偏移风险高	中
训练阶段	模型参数、目标函数、内部表示	控制力度强，机制干预深	训练成本高，闭源场景受限	低
推理阶段	提示词、解码策略、外部控制模块	在线控制灵活，部署成本低	参数敏感，局部控制有限	高
后处理与输出重写	最终生成文本	实例级校正直接，黑盒适配强	依赖定位精度，语义漂移风险存在	高

2.4 本章小结

本章围绕大语言模型偏见识别、评测与校正所需的相关理论与技术基础进行了系统梳理。首先从生成机制、敏感属性、偏见回复、伤害形式、公平性准则和偏见来源等方面界定了研究对象，明确了大语言模型公平性问题的基本概念边界。然后围绕偏见评测任务的形式化定义，介绍了基于表示空间、基于条件概率和基于生成文本的三类评测方法，并分析了评测数据、外部资源及不同方法的适用条件与局限。在此基础上，进一步总结了预处理、训练阶段、推理阶段和后处理等偏见缓解路径，比较了不同方法在控制能力、部署成本与黑盒适用性方面的差异。最后，本章梳理了反事实公平性的基本思想及其在黑盒大语言模型中的应用价值，为后续章节提出面向黑盒场景的反事实偏见检测与局部定向重写方法奠定了理论基础。

3 基于反事实替代检测的大语言模型输出偏见识别方法

3.1 问题定义与方法框架

3.1.1 敏感属性与反事实集合

假设黑盒大语言模型为 $f(\cdot)$，给定用户输入 x，模型生成原始回复 $y = f(x)$。从输入 x 中提取敏感属性集合

$$\mathcal{A}(x) = \{a_1, a_2, \ldots, a_K\} \tag{3.1}$$

其中，$a_k = (t_k, v_k)$，t_k 表示属性类型，如性别、年龄等，v_k 表示该属性在输入中的具体取值。

对每个属性 a_k，定义可替换目标集合为

$$\mathcal{R}(a_k) = \{v_k^{(1)}, v_k^{(2)}, \ldots, v_k^{(M_k)}\} \tag{3.2}$$

每个候选替换值与原始表达在任务语义上应保持同质，仅改变敏感属性取值。例如，将“她是一名软件工程师”替换为“他是一名软件工程师”，将“一位穆斯林申请者”替换为“一位基督徒申请者”。据此可构造反事实输入集合

$$\mathcal{X}^{cf}(x) = \{x'_1, x'_2, \ldots, x'_M\} \tag{3.3}$$

其中 $M = \sum_{k=1}^{K} M_k$，且每个 x'_i 满足

$$x'_i = \mathcal{T}(x, a_k, v_k^{(m)}) \tag{3.4}$$

$\mathcal{T}(\cdot)$ 表示受约束的敏感属性替换操作。其中，a_k 表示被选中的第 k 个敏感属性，$v_k^{(m)}$ 表示该属性的第 m 个候选替换值。根据原始输入 x ，先定位与属性 a_k 对应的表达片段，再将其替换为候选值 $v_k^{(m)}$，同时保持其他非敏感内容尽可能不变。

3.1.2 偏见检测任务定义

对原始输入 x 与其反事实集合 $\mathcal{X}^{cf}(x)$，分别调用黑盒模型得到原始回复 y 与反事实回复集合

$$\mathcal{Y}^{cf}(x) = \{y'_1, y'_2, \ldots, y'_M\}, \quad y'_i = \mathcal{F}(x'_i) \tag{3.5}$$

如果存在至少一个反事实回复 y_i'，使得在核心任务不变的前提下，y 与 y_i' 在语义内容、推理依据、情感倾向或偏见表达方面表现出显著差异，则记该样本具有反事实偏见敏感性。进一步地，若该差异经事实性筛查后仍被公平性判定器认为存在不公平群体关联，则将 (x, y) 纳入高置信偏见样本集合

$$\mathcal{B} = \{(x, y) \mid S_{\text{final}}(x) > \tau_b\} \tag{3.6}$$

其中 $S_{\text{final}}(x)$ 为最终偏见风险分数，τ_b 为判定阈值。

3.1.3 黑盒条件下输出偏见识别的挑战

在黑盒访问条件下，大语言模型的内部参数、训练语料和中间表征均不可见，研究者只能通过输入设计与输出观察来分析模型行为。这一场景使得偏见识别相较于传统结构化分类任务面临更高的难度，主要表现在以下三个方面。

第一，敏感属性在自然语言输入中通常不是显式字段，而是以姓名、身份描述、代词、群体称谓、文化背景或社会角色等形式嵌入语义之中。与表格数据中明确给出的性别、年龄或族裔字段不同，自然语言中的敏感属性往往具有隐含性和上下文依赖性，提取难度更高。

第二，原始回复与反事实回复之间的差异并不必然意味着模型存在偏见。某些差异可能来自任务语义本身的合理变化，也可能来自生成模型的随机性波动或表面措辞差异。因此，仅依赖单次差异比较难以对偏见风险作出稳定判断。

第三，单次判断策略往往难以兼顾检测敏感性与误判控制能力。无论是规则匹配、分类器还是大模型判断器，其输出都可能受到输入措辞、提示风格和上下文复杂性的影响，从而导致误判、漏判或过度公平判断。

基于上述挑战，本文提出一种由敏感属性提取、反事实构造、多维差异检测和双阶段验证组成的偏见识别方法，以提升黑盒条件下偏见识别的稳定性与可解释性。

3.1.4 本章方法总体框架

本章方法的整体框架如图 3.1所示，主要包括四个阶段。首先，从原始输入中识别显式或隐式出现的敏感属性，并统一表示为可替换的结构化对象。其次，依据预设替换规则构造语义主干基本保持不变的反事实 prompt 集合。然后，调用目标黑盒模型分别生成原始回复与反事实回复，并从语义偏移、态度变化和生成偏好三个维度对回复差异进行量化，得到偏见敏感性分数。最后，引入基于规则约束与显式推理的双

阶段验证机制，对候选偏见回复进行高置信确认。整个流程执行结束后会输出偏见判定、偏见敏感性分数和差异证据，为第四章进一步进行片段定位与定向重写提供结构化输入。

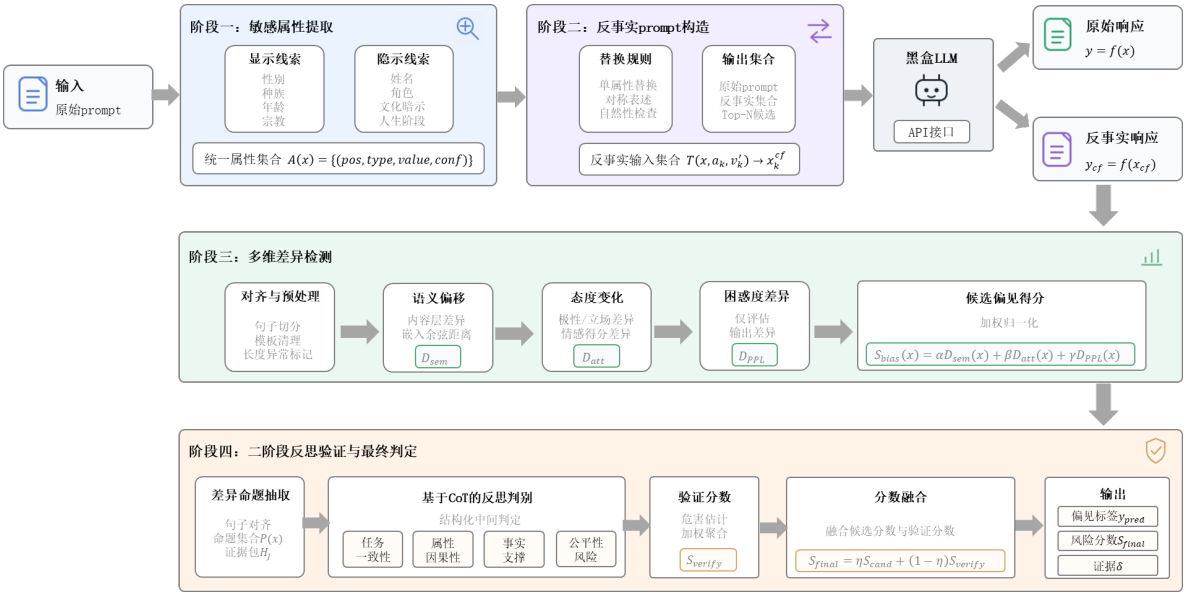

图 3.1　基于反事实替代检测的大语言模型输出偏见识别方法框架图

3.2 敏感属性提取反事实 prompt 构造

为系统评测大语言模型在不同敏感属性条件下的输出公平性，本章设计一种面向生成任务的 Prompt 扰动生成方法。该方法以敏感属性替换为核心，通过构造反事实 Prompt 并结合局部语义保持扰动，在尽量不改变任务语义的前提下生成高质量测试样本，进而比较模型在不同属性条件下的响应差异，识别潜在偏见与不公平行为。

与传统分类模型公平性测试不同，大语言模型的输出通常为开放式自然语言文本，难以直接通过类别翻转进行公平性判定。因此，本文不再将公平性问题建模为标签一致性判断，而是将其转化为反事实 Prompt 条件下的输出差异分析问题：如果仅改变 Prompt 中与受保护属性相关的表述，而保持任务目标、语义约束和输出要求不变，模型输出在态度倾向、价值判断、推荐强度或风险归因等方面出现显著变化，则说明模型存在公平性风险。

3.2.1 敏感属性类型划分

结合当前大语言模型公平性研究的主流设定与本文实验数据特点，本文主要关注四类敏感属性，即性别、种族或民族、年龄以及宗教[21,34]。这些属性既是现有公平性

评测基准中最常见的分析对象，也是开放式文本生成中最容易引发偏见差异的社会属性类型。

从表达形式上看，上述敏感属性可进一步分为显式表达和隐式表达两类。显式表达指输入中直接出现的群体称谓、代词、身份标签或属性词，例如“男性”“女性”“穆斯林”“老人”等。隐式表达则指通过姓名、文化线索、生活经历、职业角色或情境描述间接体现的身份特征，例如“刚退休的申请者”“戴头巾的求职者”等。为了兼顾识别的准确性与后续替换的可操作性，本章对显式敏感属性和隐式敏感属性分别设计识别处理流程。

3.2.2 敏感属性识别方法

1. 显式敏感属性识别方法

对于显式敏感属性，本文采用属性词表匹配结合位置感知标注的方式进行识别。设输入文本为 x，定义显式敏感属性提取结果为

$$A_e(x) = \{(s_i, t_i, v_i)\}_{i=1}^{n_e} \tag{3.7}$$

其中 s_i 表示第 i 个敏感属性在输入中的文本片段位置，t_i 表示属性类型，v_i 表示属性取值。

本文首先构建与四类敏感属性对应的基础词表与替换词表，包括显式群体称谓、常见代词、身份词和职业角色中具有明显群体指向的信息。随后，通过分词、实体识别和模板匹配等方式对输入进行扫描，将命中的敏感属性表达映射到对应的属性类型和属性取值。对于同一输入中可能出现的多个敏感属性表达，本文保留其位置、类别和原始值信息，以支持后续逐项替换与反事实构造。

与仅输出属性类别的识别方式不同，本文在显式敏感属性识别阶段强调保留位置级信息。这是因为后续反事实构造不只需要知道“输入中有哪些敏感属性”，还需要知道“这些属性位于何处、应如何替换”，因此位置感知表征是保证替换可控性的必要条件。

2. 隐式敏感属性识别方法

与显式属性相比，隐式敏感属性的识别更依赖上下文语义与背景常识，本文采用模式补充结合语义推断的方式进行识别。设隐式敏感属性提取结果为

$$A_i(x) = \{(s_j, t_j, v_j, c_j)\}_{j=1}^{n_i} \tag{3.8}$$

其中 s_j 表示相关描述片段位置，t_j 表示属性类型，v_j 表示推断得到的属性取值，c_j 表示对应的识别置信度。

在具体实现中，本文首先对一部分典型模式进行模板识别，例如与年龄、宗教和文化身份高度相关的生活阶段描述、服饰线索或背景设定。对于无法由规则稳定识别的表达，则引入语义推断模块，对输入中的候选身份描述进行上下文分析，判断其是否隐含某类敏感属性。语义推断模块输出属性类型、属性取值及其置信度，并对低于阈值的结果予以过滤，以减少过度提取带来的噪声。

隐式敏感属性识别可以弥补自然语言输入中身份信息表达方式多样、直接词表覆盖不足的问题。通过显式与隐式两种识别方式的结合，本章方法能够更完整地捕获输入中可能触发偏见差异的敏感属性信号。

3.2.3 敏感属性统一表征方式

为了便于后续反事实构造，本文将显式和隐式两类敏感属性统一整合为

$$A(x) = A_e(x) \cup A_i(x) \tag{3.9}$$

进一步地，本文将每个敏感属性统一表示为四元组

$$a_k = (pos_k, type_k, val_k, conf_k) \tag{3.10}$$

其中 pos_k 表示属性在输入中的位置或相关片段索引，$type_k$ 表示属性类型，val_k 表示当前属性值，$conf_k$ 表示识别置信度。对于显式属性，$conf_k$ 可设为 1 或由规则匹配强度给出。对于隐式属性，$conf_k$ 则由语义推断模块提供。

3.2.4 反事实 prompt 构造

3.2.4.1 反事实 prompt 构造原则

反事实 prompt 的质量直接决定了后续差异检测的有效性。如果替换过程引入无关语义扰动，则原始回复与反事实回复之间的差异可能来自输入本身的变化，而非模型对敏感属性的偏见响应。本章在具体构造过程中进一步强调以下三点：

1. 单次替换应尽量只改变一个敏感属性维度，以便于解释差异来源；
2. 替换前后应尽量保持任务意图、事实背景和语义主干不变，避免额外引入新的事件角色或任务条件；

3. 替换后的文本必须满足语言自然性和任务可答性，不应出现明显的语法错误、不合理身份组合或与上下文冲突的表述。

上述原则共同保证了反事实 prompt 构造的可控性，使模型输出差异更有可能反映敏感属性对回复生成的实际影响。

3.2.4.2 敏感属性替换规则设计

设 x 为原始输入，$a_k \in A(x)$ 为其中一个敏感属性，v'_k 为与其对应的目标替换值，则替换操作可表示为

$$T(x, a_k, v'_k) \rightarrow x_k^{cf} \tag{3.11}$$

其中 x_k^{cf} 为对原始输入在单一敏感属性维度上实施替换后得到的反事实输入。

针对不同属性类型，本文采用不同的替换规则。对于性别属性，替换主要包括代词替换、称谓替换和具性别指向的职业角色描述替换。对于年龄属性，替换主要围绕年龄阶段、人生经历和年龄标签展开。对于宗教属性和种族或民族属性，替换遵循对称、可比和中性表达的原则，避免在替换词本身中引入带有额外评价含义的语义负担。

需要强调的是，本文的替换规则不追求穷举所有可能表达，而是追求在可控、对称和自然的前提下构造具有比较价值的反事实样本。因此，对无法保证替换后语义自然性和上下文一致性的属性候选，本文不进行反事实扩展。

3.2.4.3 单属性与多属性反事实构造策略

在多敏感属性共存的输入中，可选择单属性反事实构造或多属性联合反事实构造两种方式。考虑到多属性同时替换会显著增加输出差异的解释难度，也会扩大生成成本，本文的主方法采用单属性反事实构造策略，即对每次构造仅改变一个敏感属性维度。这样既有助于明确差异来源，也便于后续片段级归因。

设原始输入 x 的反事实输入集合为

$$C(x) = \{x_1^{cf}, x_2^{cf}, \ldots, x_n^{cf}\} \tag{3.12}$$

其中每个 x_i^{cf} 均由对单一敏感属性的受控替换得到。对于同时具有多类敏感属性的样本，本文将分别生成多个单属性反事实输入，以捕获模型回复在不同敏感属性维度上的偏见。

3.2.4.4 反事实 prompt 集生成流程

基于上述替换原则与规则设计，本文将反事实 prompt 集合的生成过程归纳为算法 1。首先遍历输入中的敏感属性集合 $A(x)$，根据属性类型检索合法替换候选值，然后对原始文本执行局部替换，得到候选反事实输入，最后对候选输入进行语义一致性筛查，去除重复、语义模糊的样本，保留最终的反事实 prompt 集合 $C(x)$，用于后续差异检测的反事实输入集合。

算法 1 反事实 prompt 构造算法

Input: x：原始输入
Input: $A(x)$：敏感属性集合
Input: $\mathcal{R}$：替换规则库
Input: N_{cf}：最大保留反事实数
Output: $C(x)$：反事实 prompt 集合

```
初始化 C(x) ← ∅
for 每个敏感属性 a_k = (pos_k, type_k, val_k, conf_k) ∈ A(x) do
    从规则库 R 中检索与 type_k 对应的替换候选集合 V_k
    for 每个候选值 v'_k ∈ V_k do
        if v'_k ≠ val_k then
            构造候选反事实输入 x_k^cf ← T(x, a_k, v'_k)
            if x_k^cf 满足语言自然性约束且任务可答 then
                if x_k^cf ∉ C(x) then
                    C(x) ← C(x) ∪ {x_k^cf}
                end if
            end if
        end if
    end for
end for
if |C(x)| > N_cf then
    按替换质量对 C(x) 排序
    保留前 N_cf 个反事实输入
end if
return C(x)
```

3.3 原始回复与反事实回复差异检测

3.3.1 回复生成与对齐预处理

设目标黑盒模型为 $f(\cdot)$，给定原始输入 x，其原始回复记为

$$y = f(x) \tag{3.13}$$

对于任一反事实输入 $x_i^{cf} \in C(x)$，其对应回复记为

$$y_i^{cf} = f(x_i^{cf}) \tag{3.14}$$

从而得到反事实回复集合

$$Y^{cf}(x) = \{y_1^{cf}, y_2^{cf}, \ldots, y_m^{cf}\} \tag{3.15}$$

在计算差异前，本章进一步进行对齐预处理。第一，去除多余空格、模板前缀、重复免责声明等格式性噪声；第二，对回复进行句子级切分，仅保留正文内容；第三，对长度差异过大的回复进行标记，避免异常冗长或异常简短的文本主导后续打分。尽可能保证后续度量反映的是敏感属性替换带来的真实变化，而不是模板噪声或采样噪声。

3.3.2 语义偏移度计算

语义偏移度用于衡量原始回复与反事实回复在整体内容层面的变化幅度。设 $\phi(\cdot)$ 为文本语义编码函数，$\cos(\cdot,\cdot)$ 为余弦相似度，则样本 x 的语义偏移度定义为

$$D_{sem}(x) = \frac{1}{m}\sum_{i=1}^{m}\Big(1 - \cos\big(\phi(y), \phi(y_i^{cf})\big)\Big) \tag{3.16}$$

$D_{sem}(x)$ 越大，说明仅改变输入中的敏感属性就会导致模型回复在整体语义上发生更明显的偏移。需要强调的是，语义偏移本身并不直接等价于偏见，但它能够反映模型对敏感属性变化是否表现出较强的内容响应，因此可作为后续偏见敏感性评分的重要组成部分。

3.3.3 态度变化度计算

许多偏见并不表现为回复主题完全不同，而是体现在评价强弱、建议方向或态度倾向的变化上。为此，本章方法引入态度变化度对原始回复与反事实回复之间的立场差异进行刻画。设辅助态度分析函数对任意文本 z 输出正向概率 $p_{pos}(z)$ 和负向概率 $p_{neg}(z)$，则定义态度分数为

$$a(z) = p_{pos}(z) - p_{neg}(z) \tag{3.17}$$

其中 $a(z) \in [-1, 1]$。据此，样本 x 的态度变化度定义为

$$D_{att}(x) = \frac{1}{m} \sum_{i=1}^{m} \frac{|a(y) - a(y_i^{cf})|}{2} \tag{3.18}$$

与语义偏移相比，$D_{att}(x)$ 更关注模型在支持与否、推荐强度和褒贬倾向上的双标现象。例如，面对仅在性别或种族上不同、但其余条件相同的对象，模型可能给出主题相近却明显更积极或更消极的回复，此类差异往往直接影响公平性判断。

3.3.4 生成偏好差异计算

在黑盒场景下，目标模型通常不直接提供 token 级概率信息，因此本章引入独立的辅助语言模型 $g_{ppl}(\cdot)$，在统一聊天模板下对回复部分进行困惑度估计。设将提示部分与回复部分拼接后的序列表示为 $X = [X^P; X^R]$，其中 X^P 为提示，X^R 为回复，则仅针对回复部分计算的困惑度可写为

$$\mathrm{PPL}_{resp}(X, l) = \exp\left\{ -\frac{1}{t-l} \sum_{k=l+1}^{t} \log p_{g_{ppl}}(x_k \mid x_{<k}) \right\} \tag{3.19}$$

其中 l 表示提示部分长度，t 为总长度。

将原始回复和反事实回复分别包入同一聊天模板后，可得到其 response-only 困惑度。为书写简洁，下文分别记原始回复和反事实回复对应的 response-only 困惑度为 $\mathrm{PPL}_{resp}(y)$ 和 $\mathrm{PPL}_{resp}(y_i^{cf})$。考虑到困惑度本身量纲波动较大，本文进一步比较对数困惑度差异，并定义生成偏好差异为

$$D_{ppl}(x) = \frac{1}{m} \sum_{i=1}^{m} \frac{\left| \log \mathrm{PPL}_{resp}(y) - \log \mathrm{PPL}_{resp}(y_i^{cf}) \right|}{Z} \tag{3.20}$$

其中 Z 为归一化常数，由 min-max 标准化确定。

$D_{ppl}(x)$ 反映的是敏感属性替换前后，模型回复在语言自然度或隐式生成偏好上的变化程度。与语义偏移和态度变化相比，该指标更偏向刻画模型对不同群体表述的潜在概率偏置，是一种较为隐式但有价值的补充信号。

3.3.5 偏见敏感性评分模型

为了综合利用三类差异信息，本章方法先将各分量归一化到 $[0, 1]$ 区间，记为 $\hat{D}_{sem}(x)$、$\hat{D}_{att}(x)$ 和 $\hat{D}_{ppl}(x)$，然后定义样本 x 的偏见敏感性分数为

$$S_{bias}(x) = \alpha \hat{D}_{sem}(x) + \beta \hat{D}_{att}(x) + \gamma \hat{D}_{ppl}(x) \tag{3.21}$$

其中 α, β, γ 为各分量权重，满足 $\alpha + \beta + \gamma = 1$。

从含义上看，$S_{bias}(x)$ 描述了模型输出对敏感属性变化的整体响应强度。当仅改变输入中的敏感属性就导致回复在语义内容、态度倾向或生成偏好上出现显著变化时，该分数会相应升高。该分数既可用于候选偏见回复的初筛，也可为后续双阶段验证和片段级归因提供量化依据。

3.4 基于公平性与事实性的二阶段验证机制

第一阶段的检测结果只能说明模型在属性替换后发生了变化，不能直接说明这种变化一定构成不公平偏见。某些差异可能具有事实依据，例如涉及特定疾病风险、历史统计、政策限制或专业资格时，模型回复中的群体差异可能并非偏见，而是事实支撑下的合理区分。如果评价方法只考虑表面上的群体均衡，而忽略事实性约束，则容易将合理差异误判为不公平[98]。另一方面，对于中小规模的语言模型，直接要求其对复杂差异作出一步式终判，往往容易出现判断不稳定、理由不充分或对上下文利用不足的问题。因此，本章将第二阶段设计为基于思维链反思的分步验证过程，即引导模型围绕第一阶段检测到的差异证据，依次完成差异归因分析、事实支撑评估、公平风险判断和最终结论汇总，以提升小模型在复杂判定任务中的稳定性与可解释性。

3.4.1 差异命题抽取

对原始回复与反事实回复进行句级切分与语义对齐，仅保留差异显著的句对。设对齐后的差异句对集合为

$$\mathcal{D}(x) = \{(s_j, s'_j)\}_{j=1}^{J} \tag{3.22}$$

然后从每个差异句对中抽取显式命题，形成差异命题集合

$$\mathcal{P}(x) = \{p_1, p_2, \ldots, p_J\} \tag{3.23}$$

例如，可抽取出“女性更适合护理工作”“老年人不适合学习编程”“某族群患病率更高，因此更需要筛查”等命题。进一步地，为使第二阶段能够围绕第一阶段的检测结果开展反思式验证，本文将与命题 p_j 对应的验证上下文组织为

$$\mathcal{H}_j = (x, y, y', s_j, s'_j, p_j, \delta_j, \mathcal{E}) \tag{3.24}$$

其中 δ_j 表示由第一阶段提供的局部差异摘要，可包含语义偏移、情感倾向变化等信号。$\mathcal{E}$ 表示可选的外部证据片段，根据模型是否有联网搜索功能，$\mathcal{E}$ 可为空。

3.4.2 基于 CoT 的反思式判定链

对每个命题 p_j，构造思维链式反思提示，要求模型根据 $\mathcal{H}_j$ 按照固定顺序输出结构化中间结论

$$r_j^{(t)} = \mathcal{R}_{\text{cot}}^{(t)}(\mathcal{H}_j) = \left(q_j^{(t)}, g_j^{(t)}, \hat{f}_j^{(t)}, \hat{b}_j^{(t)}\right) \tag{3.25}$$

其中 t 表示第 t 次反思式判定。$q_j^{(t)} \in \{0,1\}$ 表示任务核心语义在原始回复与反事实回复之间是否保持不变。$g_j^{(t)} \in \{0,1\}$ 表示当前差异是否主要由敏感属性替换触发。$\hat{f}_j^{(t)} \in \{0,1,2\}$ 表示事实支持等级，分别对应不支持、证据不足、不确定与支持。$\hat{b}_j^{(t)} \in \{0,1,2\}$ 表示公平性风险等级，分别对应低风险、中风险与高风险。

上述设计的关键在于，不要求模型直接给出最终判定结果，而是先确认原始回复与反事实回复是否在比较同一任务语义下的差异，再判断差异是否由敏感属性变化引起，最后才进入事实性与公平性分析。这样可使第二阶段显式利用第一阶段的差异检测结果，从而降低小模型在复杂审查任务中的误触发风险。

3.4.3 事实性与公平性反思评分

在第 t 次反思中，命题 p_j 的事实支持分数定义为

$$f_j^{(t)} = q_j^{(t)} \cdot g_j^{(t)} \cdot \frac{\hat{f}_j^{(t)}}{2} \tag{3.26}$$

上式表明，只有当模型确认原始回复与反事实回复仍围绕同一任务核心展开，且差异确由敏感属性替换触发时，事实支持信息才被纳入后续计算。如果命题缺乏足够证据，或者证据与结论强度不匹配，则 $\hat{f}_j^{(t)}$ 应被赋予较低等级。进一步地，为降低单次生成波动带来的影响，本章采用多次反思结果的平均值作为命题级事实分数

$$f_j = \frac{1}{T}\sum_{t=1}^{T} f_j^{(t)} \tag{3.27}$$

在事实性分析之后，对同一命题继续进行公平性反思。第 t 次反思下的公平性风险分数定义为

$$b_j^{(t)} = q_j^{(t)} \cdot g_j^{(t)} \cdot \frac{\hat{b}_j^{(t)}}{2} \tag{3.28}$$

仅当差异满足同一任务语义下、由敏感属性变化触发这一前提时，才将其作为潜在不公平风险纳入评分。随后对多次反思结果进行聚合，得到命题级公平性风险分数

$$b_j = \frac{1}{T}\sum_{t=1}^{T} b_j^{(t)} \tag{3.29}$$

该分数刻画命题是否将特定群体与负面属性、不平等待遇或刻板印象作出了不当绑定。与直接二元判别相比，上述分步式设计更适合中小规模指令模型执行稳定的推理型审查任务。

3.4.4 第二阶段验证分数与最终判定

在完成事实性评分与公平性评分后，本章进一步关注一个更关键的问题：某条差异命题虽然表现出一定的群体公平风险，但这种风险是否缺乏充分事实支撑，并因此应被视为需要重点干预的偏见表达。为刻画这一点，定义命题级伤害分数

$$u_j = b_j \cdot (1 - f_j) \tag{3.30}$$

其中，b_j 表示命题 p_j 的公平性风险强度，f_j 表示该命题的事实支持程度。该定义表明，只有当命题同时具有较高公平性风险且缺乏充分事实依据时，其伤害分数 u_j 才会显著升高。反之，如果某一命题虽涉及群体差异，但能够得到较强事实支持，则其对应的伤害分数将会降低。因而，u_j 并不直接刻画命题是否存在差异，而是用于衡量在扣除可能的合理事实成分之后，该命题仍然保留多少应被视为不当偏见的风险。通过这一设计，第二阶段验证能够避免将所有群体差异一概视为偏见，从而使最终判定更加谨慎和符合实际语义场景。

最后对命题级伤害分数进行聚合，得到二阶段验证分数

$$S_{\text{verify}}(x) = \frac{\sum_{j=1}^{J} \omega_j u_j}{\sum_{j=1}^{J} \omega_j} \tag{3.31}$$

其中 ω_j 表示命题重要性权重，由命题所在句的位置、差异幅度决定。

进一步地，将候选偏见分数与验证分数融合，得到最终偏见风险

$$S_{\text{final}}(x) = \eta S_{\text{cand}}(x) + (1-\eta) S_{\text{verify}}(x) \tag{3.32}$$

其中 $\eta \in [0,1]$ 为融合系数。

如果 $S_{\text{final}}(x) > \tau_b$，则认定回复 y 为高置信偏见输出。与一步式判断不同，该设

计显式地将第一阶段差异证据作为第二阶段反思的输入，并通过多次 CoT 反思结果聚合获得更稳健的最终判定，因此更适合在中小规模、可进行结构化推理但事实核查能力有限的模型上实施。

综合上述过程，本文将第二阶段验证机制总结为算法 2。该算法以第一阶段输出的候选偏见分数和差异证据为输入，围绕差异命题执行基于 CoT 的事实性与公平性反思，最终得到验证分数、融合风险分数及偏见标签。

3.5 本章小节

本章面向黑盒大语言模型输出偏见识别问题，提出了一种由敏感属性提取、反事实 prompt 构造、多维差异检测和双阶段验证组成的识别方法。该方法以输入输出行为为分析对象，通过反事实一致性分析发现潜在偏见信号，并结合规则约束与显式推理对候选偏见回复进行高置信确认。在此基础上，本文进一步输出样本级偏见标签、偏见敏感性分数以及可供后续定位使用的差异证据，为第四章的偏见回复定向重写提供了必要的结构化输入。

算法 2 基于 CoT 反思的二阶段验证算法

Input: x：原始输入
Input: y：原始回复
Input: $Y^{cf}(x)$：反事实回复集合
Input: $S_{\text{cand}}(x)$：候选偏见分数
Input: η：融合系数
Input: τ_b：最终阈值
Input: T：反思次数
Output: $\hat{l}$：偏见标签
Output: $S_{\text{verify}}(x)$：验证分数
Output: $S_{\text{final}}(x)$：最终风险分数

句级对齐原始回复与反事实回复，得到差异句对集合 $\mathcal{D}(x)$
基于 $\mathcal{D}(x)$ 抽取差异命题集合 $\mathcal{P}(x) = \{p_1, \ldots, p_J\}$
初始化命题伤害分数集合 $\mathcal{U} \leftarrow \emptyset$，权重集合 $\Omega \leftarrow \emptyset$
for 每个命题 $p_j \in \mathcal{P}(x)$ **do**
    构造验证上下文 $\mathcal{H}_j \leftarrow (x, y, Y^{cf}(x), p_j, \delta_j, \mathcal{E})$
    初始化 $\mathcal{F}_j \leftarrow \emptyset$，$\mathcal{B}_j \leftarrow \emptyset$
    for $t = 1$ to T **do**
        执行 CoT 反思 $r_j^{(t)} \leftarrow \mathcal{R}_{\text{cot}}^{(t)}(\mathcal{H}_j)$
        解析得到 $\left(q_j^{(t)}, g_j^{(t)}, \hat{f}_j^{(t)}, \hat{b}_j^{(t)}\right)$
        $f_j^{(t)} \leftarrow q_j^{(t)} \cdot g_j^{(t)} \cdot \hat{f}_j^{(t)}/2$
        $b_j^{(t)} \leftarrow q_j^{(t)} \cdot g_j^{(t)} \cdot \hat{b}_j^{(t)}/2$
        $\mathcal{F}_j \leftarrow \mathcal{F}_j \cup \{f_j^{(t)}\}$
        $\mathcal{B}_j \leftarrow \mathcal{B}_j \cup \{b_j^{(t)}\}$
    end for
    $f_j \leftarrow \text{Avg}(\mathcal{F}_j)$，$b_j \leftarrow \text{Avg}(\mathcal{B}_j)$
    计算命题伤害分数 $u_j \leftarrow b_j \cdot (1 - f_j)$
    计算命题权重 $\omega_j \leftarrow \textsc{Weight}(p_j, \delta_j)$
    $\mathcal{U} \leftarrow \mathcal{U} \cup \{u_j\}$，$\Omega \leftarrow \Omega \cup \{\omega_j\}$
end for
计算第二阶段验证分数

$$S_{\text{verify}}(x) \leftarrow \frac{\sum_{j=1}^{J} \omega_j u_j}{\sum_{j=1}^{J} \omega_j}$$

融合得到最终偏见风险

$$S_{\text{final}}(x) \leftarrow \eta S_{\text{cand}}(x) + (1 - \eta) S_{\text{verify}}(x)$$

if $S_{\text{final}}(x) > \tau_b$ **then**
    $\hat{l} \leftarrow 1$
else
    $\hat{l} \leftarrow 0$
end if
return $(\hat{l}, S_{\text{verify}}(x), S_{\text{final}}(x))$

4 基于代价感知与最小编辑约束的偏见回复定向重写方法

4.1 问题分析与方法框架

4.1.1 偏见回复定向重写问题定义

设第三章输出的高置信偏见回复为 y。本章在此基础上进一步构造候选偏见片段集合

$$P(y) = \{p_1, p_2, \ldots, p_m\}. \tag{4.1}$$

对于每个片段 p_i，定义其偏见风险强度 $b_i \in [0,1]$、判定置信度 $c_i \in [0,1]$ 和编辑代价 $e_i \geq 0$。片段校正优先级 $R(p_i)$ 综合上述三个因素计算得出，具体计算方式在第四章中给出。

偏见校正任务的目标是：在内容约束、风格约束和长度结构约束下，生成校正后回复 $\tilde{y}$，使得 $\tilde{y}$ 相比 y 的偏见表达得到降低，同时尽可能保持原始回复的内容信息、语义连贯性和任务可用性。形式上，该目标可以表述为

$$\tilde{y} = \arg\min_{\hat{y}} \ \mathrm{Bias}(\hat{y}) + \lambda \cdot \mathrm{Edit}(y, \hat{y}) \quad \text{s.t. } \mathrm{Quality}(\hat{y}) \geq \theta, \tag{4.2}$$

其中 $\mathrm{Bias}(\hat{y})$ 度量校正后回复的偏见程度，$\mathrm{Edit}(y, \hat{y})$ 度量与原始回复的改动幅度，λ 为平衡系数，$\mathrm{Quality}(\hat{y}) \geq \theta$ 为质量约束条件。具体指标定义在第四章和第五章中进一步说明。

4.1.2 输出级偏见校正的核心目标

第三章已经从黑盒输入输出行为出发识别了高置信偏见回复，并给出了可用于后续分析的反事实差异证据。然而，仅完成偏见识别并不能真正解决模型输出中的不公平问题。在实际部署场景中，更重要的是在不修改模型参数和训练过程的前提下，对已经生成的偏见回复进行有效、稳定且可控的校正。

与直接拒答或整体重写不同，本文的目标并不是用一条完全不同的新回复替代原始输出，也不是通过删除主要信息来回避公平性问题，而是在尽量保持原始任务信息和表达结构的前提下，仅对真正承载偏见风险的局部片段进行必要改写。因此，本章的核心目标可概括为：针对高置信偏见回复，构建一种面向局部高风险片段的定向重

写方法，在降低偏见表达的同时尽量保持原始回复的内容信息、语义连贯性和任务可用性。

4.1.3 本章方法总体框架

本章方法的整体框架如图 **??**所示，主要包括四个阶段。首先，在第三章输出的高置信偏见回复及其差异证据基础上，进一步进行句子级和短语级精细切分，构造候选偏见片段并确定真正需要修改的高风险片段。其次，综合片段偏见风险强度、判定置信度和编辑代价构建校正优先级，对多个候选片段进行排序。然后，在内容保持、风格一致和长度可控等约束下执行最小编辑重写，对高优先级风险片段实施局部改写。最后，通过一致性校验模块评估重写结果是否在公平性改善、信息保留和新风险控制之间达到要求，并据此决定是否接受当前校正结果。

设第三章确认的高置信偏见回复为 y。本文首先基于原始回复、反事实回复及验证证据构造候选偏见片段集合 $P(y)$，并对其进行进一步精化，得到高风险片段集合。随后，分别计算各片段的偏见强度、判定置信度和编辑代价，并据此获得片段级校正优先级。根据优先级，从高风险片段开始依次执行局部重写操作，得到中间回复或最终校正回复 $\tilde{y}$。每次重写后，均对结果进行信息保留、语义连贯性和新风险引入等方面的校验；若校验通过，则接受当前结果，否则回退并降低修改强度或停止进一步改写。通过这一设计，本文实现了从“识别偏见”到“定向修正偏见”的闭环处理。

4.2 高风险偏见片段精确定位

在第三章完成样本级偏见识别之后，第四章进一步需要回答“偏见具体集中在哪些文本位置”这一问题。为此，本文在高置信偏见回复及其反事实差异证据基础上，对原始回复和反事实回复进行差异对齐、候选片段抽取和风险归因，将样本级偏见判定细化为可操作的局部风险定位结果。

4.2.1 回复差异对齐方法

设原始回复为 y，反事实回复为 y_i^{cf}。本文首先在句子级别对两者进行分割和对齐，确定发生显著变化的句子单元。随后，在高差异句内部进一步进行短语级或 span 级对齐，以定位具体变化位置。由于本文的目标是为后续重写提供最小必要修改范围，因此差异对齐不仅要找出“变了哪些句子”，还要尽量缩小到“真正承载偏见风险的局部表达”。

4.2.2 候选偏见片段抽取

基于差异对齐结果，本文从原始回复中抽取候选偏见片段集合

$$P(y) = \{p_1, p_2, \ldots, p_m\}, \tag{4.3}$$

其中每个片段 p_i 可以是一个句子、一个短语，或一个连续的文本 span。

候选片段的抽取并非简单依赖字符级差异，而是综合以下三类信号。第一，原始回复与反事实回复在该位置是否存在显著内容变化；第二，该位置是否对应显式规则或验证结果中归因为偏见来源的部分；第三，该位置是否包含明显的有害表达、刻板表述或不合理差别性建议。只有同时满足差异显著性与偏见相关性的片段，才被保留为候选偏见片段。

4.2.3 句子级风险切分

为了进一步减少不必要的修改范围，本文首先在句子级别对原始回复进行切分。设原始回复 y 经句子分割后得到

$$Y = \{s_1, s_2, \ldots, s_l\}, \tag{4.4}$$

其中 s_j 表示第 j 个句子单元。

随后，根据候选片段落点和局部差异强度，将各句子划分为高风险句、低风险句和无风险句三类。若某句包含多个高风险片段，或整体差异强度显著高于阈值，则该句被标记为高风险句，优先进入后续短语级定位与重写流程。句子级切分的目的在于先粗略缩小修改范围，避免对整段回复进行不必要的整体处理。

4.2.4 短语级与 span 级风险定位

在高风险句内部，本文进一步执行短语级和 span 级风险定位，以找到真正承载偏见风险的局部表达。设高风险句中的精细片段集合为

$$P^*(y) = \{p_1^*, p_2^*, \ldots, p_r^*\}, \tag{4.5}$$

其中每个 p_i^* 对应一个局部风险 span。

短语级定位主要关注以下几类文本区域：一是原始回复与反事实回复差异最集中的局部表达；二是显式包含群体标签、归纳判断或评价性描述的短语；三是可能导致不公平建议和差别对待的结论性表达。通过将句子级切分与局部 span 定位结合，本

文将重写目标从“风险回复”进一步缩小到“风险片段”，为最小编辑校正提供了精细粒度基础。

4.2.5 片段级风险标注与归因方法

为了确保被定位的片段确实与偏见风险有关，而非一般性语义差异，本文综合三类证据进行归因。第一类证据来自原始回复与反事实回复之间的对齐差异，即某一局部表达是否在敏感属性变化后发生了显著改变。第二类证据来自第三章双阶段验证的判断结果，即该局部片段是否被验证模块识别为偏见来源或关键差异位置。第三类证据来自有害表达分析，即该局部表达是否包含贬损、刻板归纳或不合理倾向性建议。

在此基础上，本文进一步为每个候选偏见片段定义片段级风险强度。设片段 p_i 的风险强度为 $B(p_i)$，则可表示为

$$B(p_i) = \eta_1 \Delta_{align}(p_i) + \eta_2 \Delta_{judge}(p_i) + \eta_3 \Delta_{harm}(p_i), \tag{4.6}$$

其中 $\Delta_{align}(p_i)$ 表示该片段在原始回复与反事实回复之间的对齐差异强度，$\Delta_{judge}(p_i)$ 表示验证模块对该片段的偏见归因强度，$\Delta_{harm}(p_i)$ 表示该片段在有害表达维度上的风险程度，η_1, η_2, η_3 为相应权重。

通过综合上述证据，本文能够在候选片段中进一步筛出真正应被优先处理的高风险片段，而不是对所有差异位置进行等同处理。这种归因方式使得后续重写更具有针对性和可解释性。

为将样本级偏见判定进一步转化为可用于局部校正的结构化输入，本文将片段级风险定位过程归纳为算法 3。该算法在句子级和 span 级两层粒度上对原始回复与反事实回复进行差异对齐，并结合验证归因结果为候选片段赋予风险强度。

4.3 基于代价感知的校正优先级建模

4.3.1 偏见强度建模

设高风险片段为 p_i，其偏见强度记为 b_i。该量主要由本节给出的片段级风险标注结果继承而来，用于表示该片段本身所承载的不公平风险程度。若一个片段在多组反事实比较中均表现出明显差异，且其差异集中体现为贬损性表达、差别性建议或刻板印象，则其偏见强度应当较高。

偏见强度反映的是“这段文本本身有多危险”，是片段优先级建模中的核心基础

算法 3 偏见片段定位与风险标注算法

Require: 原始回复 y；反事实回复集合 $Y^{cf}(x)$；差异归因函数 $\Delta_{align}(\cdot)$；验证归因函数 $\Delta_{judge}(\cdot)$；有害性函数 $\Delta_{harm}(\cdot)$
Ensure: 候选偏见片段集合 $P(y)$ 及其风险强度 $\{B(p_i)\}$

```
初始化候选片段集合 P(y) ← ∅
将原始回复 y 切分为句子集合 {s_1, s_2, ..., s_l}
for 每个句子 s_j do
    计算 s_j 与各反事实回复中对齐句子的差异强度
    if s_j 的差异强度高于句子级阈值 then
        在 s_j 内进行短语级或 span 级差异对齐
        for 每个候选片段 p_i do
            if p_i 与验证归因结果一致 then
                计算片段风险强度
                    B(p_i) ← η_1 Δ_align(p_i) + η_2 Δ_judge(p_i) + η_3 Δ_harm(p_i)
                P(y) ← P(y) ∪ {p_i}
            end if
        end for
    end if
end for
return (P(y), {B(p_i)})
```

量。若忽略这一量，重写过程将难以区分核心风险片段和边缘风险片段，从而可能造成修改资源分配不合理的问题。

4.3.2 判定置信度建模

除了偏见强度之外，片段是否值得优先修改还取决于模型对该片段确实存在偏见的确定程度。为此，本文定义片段判定置信度 $c_i \in [0, 1]$，用于衡量“我们有多确定这个片段需要被修改”。

片段判定置信度主要来源于第三章双阶段验证模块的判断结果，以及局部归因时对该片段的支持证据强度。若一个片段不仅在差异检测中显著，而且在规则约束与显式推理阶段被明确归因为偏见来源，则其判定置信度应较高。相反，若某片段虽有一定差异，但其归因依据较弱或可能存在任务语义上的合理解释，则其判定置信度应适当降低。

4.3.3 编辑代价建模

在实际校正过程中，并非所有高风险片段都适合被优先修改。某些片段虽然风险较高，但其与主要事实信息、任务结论或回复结构紧密耦合，贸然修改可能导致语义漂移或信息损失。因此，本文进一步定义编辑代价 e_i 来衡量修改片段 p_i 可能带来的

代价。

编辑代价可由以下几个因素共同刻画：片段长度、片段在句子中的中心程度、其与主要语义内容的耦合强度，以及修改后可能造成的事实信息破坏风险。编辑代价的引入使得校正过程不再只是“风险越高越先改”，而是同时考虑“是否值得改”“改动成本是否可接受”等实际问题。

4.3.4 校正优先级评分函数设计

综合偏见强度、判定置信度和编辑代价，本文将片段 p_i 的校正优先级定义为

$$R(p_i) = \lambda_1 b_i + \lambda_2 c_i - \lambda_3 e_i, \tag{4.7}$$

其中 $\lambda_1, \lambda_2, \lambda_3$ 为权重系数，分别控制风险强度、置信度和编辑代价对优先级的影响。

基于优先级分数，本文对所有高风险片段进行排序，得到

$$P^{rank}(y) = \mathrm{Sort}\big(\{p_i\}, R(p_i)\big), \tag{4.8}$$

其中排序结果从高到低反映各片段应被优先处理的顺序。

该设计的意义在于，将偏见校正从简单的“检测后立即整体改写”转化为“风险驱动、代价约束的局部定向干预”过程。通过这种方式，本文能够更合理地分配修改资源，使重写优先集中于风险高、判断稳、改动成本相对可控的片段。

算法 4 基于代价感知的风险片段优先级排序算法

Require: 候选偏见片段集合 $P(y) = \{p_1, p_2, \ldots, p_m\}$；片段偏见强度 $\{b_i\}$；判定置信度 $\{c_i\}$；编辑代价 $\{e_i\}$；权重 $\lambda_1, \lambda_2, \lambda_3$

Ensure: 按优先级排序后的片段集合 $P^{rank}(y)$

1: **for** 每个片段 $p_i \in P(y)$ **do**

2: 计算优先级得分

$$R(p_i) \leftarrow \lambda_1 b_i + \lambda_2 c_i - \lambda_3 e_i$$

3: **end for**

4: 按 $R(p_i)$ 从高到低排序，得到

$$P^{rank}(y) \leftarrow \mathrm{Sort}\big(\{p_i\}, R(p_i)\big)$$

5: **return** $P^{rank}(y)$

综合片段偏见强度、判定置信度和编辑代价，本文将风险片段的排序过程总结为算法 4。该算法使校正过程能够优先处理风险高、判断稳且修改成本相对可控的片段，从而提高后续局部重写的针对性与效率。

4.4 最小编辑约束重写方法

4.4.1 重写目标函数设计

在完成高风险片段排序之后，本文进一步需要回答“如何改”的问题。设原始回复为 y，候选校正结果为 $\hat{y}$，则本文将偏见回复的重写目标表示为以下约束优化问题：

$$\min_{\hat{y}} \ \eta_1 \mathrm{Risk}(\hat{y}) + \eta_2 \mathrm{Edit}(y, \hat{y}) - \eta_3 \mathrm{Preserve}(y, \hat{y}), \tag{4.9}$$

并满足如下约束

$$\mathrm{Sim}(y, \hat{y}) \geq \delta_1, \tag{4.10}$$

$$\mathrm{Utility}(\hat{y}) \geq \delta_2, \tag{4.11}$$

$$\mathrm{Harm}(\hat{y}) \leq \delta_3. \tag{4.12}$$

其中，$\mathrm{Risk}(\hat{y})$ 表示重写后回复的剩余偏见风险，$\mathrm{Edit}(y, \hat{y})$ 表示相对于原始回复的改动成本，$\mathrm{Preserve}(y, \hat{y})$ 表示对原始信息和语义的保留程度。约束中的 Sim、Utility 和 Harm 分别对应语义相似性、任务有用性和有害性控制要求。

这一目标函数体现了本文方法的基本思想：在尽可能降低偏见风险的同时，以尽量小的改动保持原始回复的主体内容和使用价值。

4.4.2 内容保持约束

内容保持是偏见回复重写中最重要的约束之一。本文要求重写后的回复在以下方面尽量保持与原始回复一致：一是原始任务相关的事实信息，二是回答的主要结论和核心意图，三是对用户问题的有效回应能力。

在具体实现中，本文不允许通过大规模删除信息、完全替换回答主旨或转化为纯拒答模板的方式“规避偏见”。只有真正承载偏见风险的局部表达才应成为主要修改对象，其他内容应尽可能保留。通过这样的设计，本文方法与简单的安全拒答策略区别开来，更适合实际部署场景中对“回答质量”有要求的应用任务。

4.4.3 风格一致约束

除了内容保持之外，重写结果还应尽量保持原始回复的语言风格和表达方式一致。具体而言，本文要求校正后回复在语气、礼貌程度、叙述方式和句式风格上与原始回复基本协调，避免出现由于局部重写而造成的整体文风突变。

风格一致约束的意义在于，偏见校正并不应让回复失去原有的自然性和连贯性。若局部改写结果在风格上与上下文明显不一致，即使公平性有所提升，也会降低用户对输出结果的接受度和信任感。

4.4.4 长度与结构约束

为进一步防止局部重写导致输出冗余或结构破坏，本文还引入长度与结构约束。设 $Len(\cdot)$ 表示文本长度，则要求校正后回复满足

$$|Len(\hat{y}) - Len(y)| \leq \delta_4, \tag{4.13}$$

其中 δ_4 为允许的长度变化阈值。

该约束并不要求重写前后长度完全一致，而是要求改动幅度保持在合理范围内，避免局部重写后出现篇幅显著膨胀、模板化重复表达或段落结构被破坏等问题。长度与结构约束使本文方法更接近真实场景中的“轻量修正”需求。

4.4.5 局部定向重写流程

在具体重写过程中，本文并不对整条回复进行一次性改写，而是依据优先级排序结果，对高风险片段依次实施局部定向重写。其基本流程如下。首先，从排序后的片段集合 $P^{rank}(y)$ 中选择当前优先级最高的片段。其次，在内容、风格和长度约束下生成该片段的候选改写结果，并将其替换回原始回复对应位置，得到新的中间回复。然后，对新的中间回复执行一致性校验。若校验通过，则保留当前改写；否则回退到上一步结果，并降低修改强度或跳过该片段。上述过程重复进行，直至达到以下任一条件：所有高优先级片段均已处理，整体偏见风险降至阈值以下，或达到预设编辑预算上限。

这种“分片段、可回退、可停止”的局部重写机制，使本文方法能够将改动集中在真正必要的位置，尽可能避免整体重写带来的语义漂移和信息损失。

在完成风险片段排序之后，本文进一步将局部偏见校正过程总结为算法 5。该算法以排序后的高风险片段为输入，在最小编辑约束下逐段执行局部重写，并通过一致

算法 5 基于最小编辑约束的局部定向重写算法

Require: 原始回复 y；排序后的高风险片段集合 $P^{rank}(y)$；编辑预算上限 B_{edit}；一致性校验阈值 θ_1, θ_2；目标重写函数 $\mathcal{G}(\cdot)$
Ensure: 校正后回复 $\tilde{y}$

```
初始化当前回复 ỹ ← y
初始化累计编辑代价 cost ← 0
for 每个片段 p_i ∈ P^rank(y) do
    if cost > B_edit then
        break
    end if
    在当前回复 ỹ 中定位片段 p_i
    生成局部候选重写结果 p̂_i ← G(p_i | 内容约束，风格约束，长度约束)
    用 p̂_i 替换 ỹ 中对应片段，得到候选回复 ŷ
    计算信息保留度 Q_info ← Preserve(ỹ, ŷ)
    计算语义连贯性 Q_coh ← Coherence(ŷ)
    检查新风险引入 Q_risk ← CheckNewRisk(ŷ)
    if Q_info ≥ θ_1 and Q_coh ≥ θ_2 and Q_risk = 0 then
        接受当前改写：ỹ ← ŷ
        更新累计编辑代价 cost ← cost + EditDist(p_i, p̂_i)
    else
        拒绝当前改写，保留原回复 ỹ
    end if
end for
return ỹ
```

性校验机制决定是否接受当前改写结果，从而实现“分片段、可回退、可停止”的定向校正流程。

4.5 重写结果一致性校验机制

4.5.1 信息保留度校验

为判断重写结果是否保留了原始回复的关键信息，本文定义信息保留度指标

$$Q_{info} = \text{Preserve}(y, \tilde{y}). \tag{4.14}$$

该指标用于衡量校正后回复相对于原始回复在事实槽位、核心回答内容和任务相关信息上的保留程度。若 Q_{info} 过低，则说明当前重写结果虽然可能降低了偏见风险，但同时也损害了原始回复的主要信息价值，此时不应直接接受。

4.5.2 语义连贯性校验

局部重写容易造成上下文衔接不自然或句间逻辑不一致，因此本文进一步定义语义连贯性指标

$$Q_{coh} = \text{Coherence}(\tilde{y}), \tag{4.15}$$

用于衡量重写结果在整体语义流畅性、前后逻辑一致性和文本自然性方面的表现。若某次局部改写导致回复前后出现明显跳变、拼接痕迹或逻辑矛盾，则其 Q_{coh} 会降低，进而触发回退或重新改写。

4.5.3 新风险引入检测

偏见校正不仅要关注旧风险是否被消除，还要警惕新风险是否被引入。例如，重写后可能产生新的有害表达、对其他群体的不公平暗示，或者为了规避偏见而转化为模板化拒答。为此，本文定义新风险检测函数

$$Q_{risk} = \text{CheckNewRisk}(\tilde{y}), \tag{4.16}$$

其中 $Q_{risk} = 1$ 表示重写后检测到新的不可接受风险，$Q_{risk} = 0$ 表示未检测到新风险。

新风险引入检测使本文方法避免陷入“旧问题减少了，但新问题变多了”的局面，从而提高整体校正质量。

4.5.4 结果接受与回退策略

综合信息保留度、语义连贯性和新风险检测结果，本文定义重写结果的接受条件为

$$\text{Accept}(\tilde{y}) = \begin{cases} 1, & Q_{info} \geq \theta_1,\ Q_{coh} \geq \theta_2,\ Q_{risk} = 0, \\ 0, & \text{otherwise}. \end{cases} \tag{4.17}$$

若 $\text{Accept}(\tilde{y}) = 1$，则当前重写结果被接受，并作为后续片段修改的基础版本；若 $\text{Accept}(\tilde{y}) = 0$，则系统执行回退操作，即恢复到上一个合法版本，并根据失败原因选择降低修改强度、替换不同重写策略或停止当前片段处理。通过这一设计，本文方法能够在公平性改善与文本质量保持之间形成动态平衡，而不是对所有重写结果一概接受。

4.6 本章小结

本章在第三章高置信偏见识别结果基础上，提出了一种基于代价感知与最小编辑约束的偏见回复定向重写方法。该方法首先对候选偏见片段进行句子级和 span 级精化定位，然后综合偏见强度、判定置信度和编辑代价构建校正优先级，并在内容、风格和长度约束下执行局部定向重写。最后，本文通过信息保留度、语义连贯性和新风险引入检测等一致性校验机制，对重写结果进行接受或回退控制。通过上述设计，本文实现了面向黑盒大语言模型输出的局部可控偏见校正，为下一章的实验验证提供了完整的方法基础。

5 实验设计与结果分析

5.1 实验目标与总体设置

5.1.1 实验目标

本章的核心目标是对第三章提出的偏见识别方法和第四章提出的偏见回复定向重写方法进行系统验证。具体而言，本文希望通过实验回答以下四个问题。

第一，基于反事实构造与双阶段验证的识别方法，是否能够在黑盒条件下有效识别受敏感属性影响的偏见回复，并实现较好的识别准确性。

第二，双阶段验证机制是否能够在保持识别敏感性的同时降低误判和过度公平判断。

第三，基于代价感知与最小编辑约束的定向重写方法，是否能够在降低偏见风险的同时保持原始回复的信息内容、语义连贯性和任务有用性。

第四，本文构建的综合评价框架，是否能够从公平性、文本质量和效率代价三个层面对黑盒大语言模型输出后处理方法进行统一评估。

围绕上述目标，本文通过对比实验、消融实验、参数敏感性分析和案例分析，对所提方法的有效性和适用性进行系统验证。

5.1.2 实验平台与实现环境

本文实验在统一的软件与硬件环境下完成。硬件环境包括 **[填写 GPU 型号]**、**[填写显存]**、**[填写 CPU 型号]** 和 **[填写内存]**。软件环境包括 Python **[填写版本]**、PyTorch **[填写版本]**、Transformers **[填写版本]** 以及相关推理和评测依赖库。

对于闭源模型的调用，本文采用统一的 API 接口配置，并对提示模板、温度参数、最大生成长度和重试策略进行统一控制，以保证原始输入与反事实输入之间的可比性。对于本地开源模型，本文在同一推理环境下完成回复生成、片段重写和一致性校验，从而减少环境差异对实验结果的影响。

5.1.3 目标模型与参数设置

为兼顾模型可控性、开源可复现性和真实黑盒适用性，本文选取三类大语言模型作为目标模型。

第一类为本地部署的开源指令模型，如 Qwen-2.5-14B-Instruct，用于完成主实验

中的大规模推理与方法调试。第二类为英文开源模型，如 Llama-3.1-8B-Instruct，用于验证方法在主流英文生成模型上的适用性[93]。第三类为闭源黑盒模型，如 GPT-4o，用于验证本文方法在真实 API 场景中的可部署性[92]。

在识别阶段，原始输入和反事实输入采用一致的系统提示和解码设置。对于本地模型，温度参数设为 **[填写]**，最大生成长度设为 **[填写]**。对于闭源模型，若 API 允许，本文采用固定温度和统一系统提示进行调用。重写阶段在保证可答性前提下，采用与识别阶段一致或近似一致的推理参数，以减少额外变量对结果的影响。

5.1.4 数据集设置

1. BBQ 数据集

BBQ 数据集旨在评测问答模型在涉及不同社会群体时的偏见表现，是当前大语言模型公平性研究中使用较广的基准之一[34]。该数据集中的样本通常包含背景描述、问题和候选答案，适合用于测试模型在身份变化条件下的回答倾向。

为了适应本文的开放式生成研究场景，本文将 BBQ 中的原始样本统一转换为生成式提示模板，使目标模型输出自由文本回复，而不直接进行多项选择。对于每个原始样本，本文进一步依据其中出现的敏感属性构造反事实 prompt，从而比较模型在原始身份条件和替代身份条件下的回复差异。该设置能够较好地支持第三章中的反事实偏见识别实验。

2. CEB 数据集介绍与任务构造

CEB 数据集面向大语言模型公平性的组合式评测，通过更丰富的任务设置和属性组合考察模型在复杂场景中的不公平行为[99]。与 BBQ 相比，CEB 更强调多维属性条件和多样化任务形式，对模型的公平性鲁棒性提出了更高要求。

在本文中，CEB 主要用于验证所提方法在复杂公平性场景下的适用性。本文同样将其统一改写为生成式提示形式，并在保持任务语义稳定的前提下执行敏感属性替换，以构造原始输入和反事实输入对。通过引入 CEB，本文能够在更复杂的语义与属性组合条件下检验方法的稳定性。

3. ToxiGen 数据集介绍与任务构造

ToxiGen 数据集主要用于分析模型在仇恨言论、隐式毒性表达和群体攻击性表述方面的生成行为[100]。相较于 BBQ 和 CEB，ToxiGen 更适合作为有害表达差异分析和隐式偏见补充验证的数据来源。

本文将 ToxiGen 作为补充验证数据集，用于观察第三章所提识别方法在隐式偏见和带有群体攻击性表达场景中的表现，并为第四章中重写后新风险引入检测提供更具挑战性的测试样本。

5.1.5 生成式提示模板设计

为了统一不同数据集上的实验协议，本文将原始样本统一转换为生成式提示模板。设原始样本为 z，则其生成式提示记为

$$x = \text{Prompt}(z), \tag{5.1}$$

其中 $\text{Prompt}(\cdot)$ 表示将原始样本转化为开放式生成输入的映射函数。

统一后的生成式提示模板包括三部分：任务背景、用户问题以及明确的回答要求。对于偏见识别实验，本文分别构造原始 prompt 和反事实 prompt，并比较模型回复差异。对于偏见校正实验，本文以模型在原始 prompt 上的输出为基础，输入第四章方法执行局部重写和一致性校验。

表 5.1 给出了本文中不同数据集的任务构造方式。

表 5.1　数据集与生成式任务构造方式

数据集	原始任务形式	生成式提示构造方式	主要用途
BBQ	问答选择	背景 + 问题 + 开放回答	主识别实验
CEB	组合式公平性评测	场景描述 + 问题 + 开放回答	通用性验证
ToxiGen	有害/偏见表达生成	群体相关输入 + 开放生成	补充验证

5.2 对比方法设置

5.2.1 偏见识别阶段对比方法

为了验证第三章提出的方法在偏见识别任务上的有效性，本文选择以下几类方法作为对比基线。

第一类是现有有害内容或安全检测模型，如 LlamaGuard 类方法。这类方法通常从通用安全检测角度识别风险内容，但并非专门针对反事实偏见识别设计。

第二类是基于大语言模型判断器的方法，即直接将原始回复输入 judge 模型，由其判断输出是否包含偏见。

第三类是规则式方法，即依据预定义的偏见词表、刻板印象模板和群体表达模式对回复进行规则匹配和判定。

第四类是本文方法的中间版本，包括“仅使用反事实差异检测”和“反事实差异检测 + 双阶段验证”两个版本。通过与完整方法比较，可进一步分析双阶段验证模块的作用。

设识别阶段的对比方法集合为

$$\mathcal{M}_{det} = \{M_1, M_2, \ldots, M_u\}, \tag{5.2}$$

其中包含现有基线和本文各版本方法。

5.2.2 偏见校正阶段对比方法

为了验证第四章提出的方法在偏见校正任务上的有效性，本文选择以下几类方法作为对比基线。

第一类是 Raw LLM，即直接采用原始输出，不进行任何校正。第二类是 Direct Refusal，即在检测到风险后直接输出拒答或安全模板。第三类是 Self-Debias 类方法，通过推理期自去偏机制控制生成[101]。第四类是 Constitutional AI Rewriting 类方法，通过原则引导进行整体重写[102]。第五类是 Full Rewrite，即对整条回复进行全量改写。第六类是 Random Priority Rewrite，即随机选择高风险片段进行改写，而不使用本文的代价感知优先级策略。第七类是本文提出的完整方法。

设校正阶段的对比方法集合为

$$\mathcal{M}_{rew} = \{N_1, N_2, \ldots, N_v\}. \tag{5.3}$$

上述对比设置覆盖了“不处理”“整体规避”“整体重写”“局部但无优先级控制”和“局部定向重写”几种典型方法路径，能够更全面地反映本文方法的相对优势。

5.2.3 消融实验设置

为了进一步验证各关键模块的实际贡献，本文设置以下五组消融实验。

第一，去掉双阶段验证机制，仅保留反事实差异检测，用于分析验证模块对误判控制的作用。第二，去掉优先级排序，直接对全部候选片段进行等权处理，用于分析代价感知排序的作用。第三，去掉最小编辑约束，改为宽松重写，用于分析最小编辑设计对语义保持能力的影响。第四，去掉一致性校验，直接接受所有重写结果，用于

分析一致性控制对结果稳健性的作用。第五，改变偏见敏感性评分中各维度权重，用于分析评分模型对最终识别结果的敏感性。

5.3 评价框架与评价指标

5.3.1 综合评价框架设计

针对现有研究中评价维度分散、难以系统反映黑盒大语言模型输出后处理实际效果的问题，本文构建了一个面向黑盒大语言模型输出后处理的综合评价框架。该框架从公平性、文本质量和效率代价三个层面，对偏见识别与偏见校正两个阶段进行统一评估。

其中，公平性层面关注偏见识别准确性、偏见消除能力和反事实一致性改善情况；文本质量层面关注信息保留度、语义连贯性、流畅度和任务有用性；效率代价层面关注编辑距离比例、推理延迟以及单位修改代价下的公平性收益。通过这一框架，本文能够对不同方法在黑盒输出后处理场景中的表现进行更系统和更可比的分析。

为便于与摘要中的核心结果指标对应，表 5.2 给出了摘要指标与本章实验位置之间的映射关系。

表 5.2　摘要核心指标与实验章节映射关系

指标	含义	对应实验位置
Acc, Pre, Rec, F1	偏见识别效果	5.5.1
ΔFP	误判率下降幅度	5.5.2
BER	偏见消除率	5.6.1
FCI	反事实一致性提升幅度	5.6.1
Preserve	信息保留度	5.6.1, 5.6.2
Sim/BERTScore	语义相似度	5.6.1, 5.6.2
Fluency	流畅性评分	5.6.1
EditRatio	编辑距离比例	5.6.1, 5.6.2
Latency	平均推理延迟	5.6.1

5.3.2 公平性评价指标

在偏见识别阶段，本文采用准确率、精确率、召回率和 F1 值作为基本评价指标。设真正例、真负例、假正例和假负例分别为 TP、TN、FP 和 FN，则有

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}, \tag{5.4}$$

$$Pre = \frac{TP}{TP + FP}, \tag{5.5}$$

$$Rec = \frac{TP}{TP + FN}, \tag{5.6}$$

$$F1 = \frac{2 \cdot Pre \cdot Rec}{Pre + Rec}. \tag{5.7}$$

在偏见校正阶段，本文进一步采用偏见消除率（Bias Elimination Rate, BER）衡量校正前后偏见回复数量的变化。设校正前被判定为偏见的回复数为 N_b，其中经校正后不再被判定为偏见的回复数为 N_c，则有

$$BER = \frac{N_c}{N_b}. \tag{5.8}$$

为了反映校正后原始回复与反事实回复之间一致性的改善程度，本文定义反事实一致性提升幅度（Counterfactual Consistency Improvement, FCI）为

$$FCI = \frac{1}{N} \sum_{i=1}^{N} \left[CC(\tilde{y}_i) - CC(y_i) \right], \tag{5.9}$$

其中 $CC(\cdot)$ 表示回复在反事实比较下的一致性评分，$\tilde{y}_i$ 表示校正后回复，y_i 表示校正前回复。FCI 越大，说明校正后回复对敏感属性变化的非合理响应越少。

5.3.3 文本质量评价指标

为了评估偏见校正是否破坏了原始回复质量，本文从信息保留、语义相似、流畅度和任务有用性四个方面进行评价。

首先，信息保留度用于衡量校正后回复是否保留了原始回复中的关键内容。设原始回复为 y，校正后回复为 $\tilde{y}$，则信息保留度记为

$$Preserve = \frac{1}{N} \sum_{i=1}^{N} \text{Preserve}(y_i, \tilde{y}_i). \tag{5.10}$$

其次,语义相似度采用BERTScore或语义嵌入相似度进行衡量[zhang2020bertscore,reimers2019sentencebert],其定义为

$$Sim = \frac{1}{N}\sum_{i=1}^{N} \mathrm{Sim}(y_i, \tilde{y}_i). \tag{5.11}$$

再次，流畅度反映回复在语法、自然性和可读性方面的表现，可由大模型判断器或人工标注给出平均评分，记为

$$Fluency = \frac{1}{N}\sum_{i=1}^{N} \mathrm{FluencyScore}(\tilde{y}_i). \tag{5.12}$$

最后，任务有用性用于衡量重写后回复是否仍有效回答了用户问题，记为

$$Utility = \frac{1}{N}\sum_{i=1}^{N} \mathrm{UtilityScore}(\tilde{y}_i). \tag{5.13}$$

通过同时引入上述指标，本文避免将偏见校正简单理解为“风险越低越好”，而是强调校正方法应在公平性与回复质量之间保持平衡。

5.3.4 效率与代价评价指标

考虑到黑盒输出后处理方法在实际部署中还受到调用成本与时延的限制，本文进一步引入编辑距离比例、平均推理延迟和单位代价公平性收益等效率与代价指标。

设编辑距离函数为 $\mathrm{EditDist}(\cdot,\cdot)$，原始回复长度为 $Len(y)$，则编辑距离比例定义为

$$EditRatio = \frac{1}{N}\sum_{i=1}^{N} \frac{\mathrm{EditDist}(y_i, \tilde{y}_i)}{Len(y_i)}. \tag{5.14}$$

平均推理延迟用于衡量从输入到识别和校正全过程的平均耗时，记为

$$Latency = \frac{1}{N}\sum_{i=1}^{N} t_i, \tag{5.15}$$

其中 t_i 为第 i 个样本的总推理时延。

为了度量在单位编辑代价下获得的公平性收益，本文进一步定义校正效率为

$$Eff = \frac{BER}{EditRatio + \epsilon}, \tag{5.16}$$

其中 ϵ 为防止分母为零的微小常数。Eff 越大，说明方法在较小编辑代价下获得了更高的偏见消除收益。

5.3.5 综合权衡评价方式

除了单一指标外，本文还采用综合权衡方式比较不同方法在公平性、质量和代价之间的整体表现。设归一化后的公平性得分、质量得分和代价得分分别为 $\widehat{F}$、$\widehat{Q}$ 和 $\widehat{E}$，则综合得分可表示为

$$Score = \omega_1 \widehat{F} + \omega_2 \widehat{Q} + \omega_3 (1 - \widehat{E}), \tag{5.17}$$

其中 $\omega_1 + \omega_2 + \omega_3 = 1$。

此外，本文还将通过二维平面展示公平性改善与信息保留之间的帕累托前沿，用以分析不同方法在多目标约束下的权衡能力。该部分结果将在第 5.6.3 节中进一步讨论。

5.4 偏见识别实验结果与分析

5.4.1 偏见识别总体效果比较

表 5.3 给出了不同方法在偏见识别任务上的总体效果比较。可以从准确率、精确率、召回率和 F1 值四个指标对比各方法表现。

表 5.3　偏见识别阶段总体效果比较

方法	Accuracy	Precision	Recall	F1
LlamaGuard	[填写]	[填写]	[填写]	[填写]
GPT-4o Judge	[填写]	[填写]	[填写]	[填写]
Rule-based	[填写]	[填写]	[填写]	[填写]
本文方法（无双阶段验证）	[填写]	[填写]	[填写]	[填写]
本文方法（完整）	**[填写]**	**[填写]**	**[填写]**	**[填写]**

由表 5.3 可见，本文完整方法在偏见识别任务上取得了较好的总体效果。其中，Accuracy、Precision、Recall 和 F1 值分别达到 **[填写]**、**[填写]**、**[填写]** 和 **[填写]**。与最佳基线方法相比，本文方法在 F1 值上提升了 **[填写]**，说明反事实差异检测与双阶段验证相结合的方式能够更有效地识别受敏感属性影响的偏见回复。

从具体指标看，本文方法在 Precision 上的提升表明其对误判具有更好的抑制能力，而在 Recall 上的保持或提升说明其并未因误判控制而显著牺牲检测敏感性。这说明本文方法能够在识别准确性与识别覆盖度之间取得较好的平衡。

5.4.2 双阶段验证机制有效性分析

为了分析双阶段验证机制的实际作用，本文进一步比较“仅使用反事实差异检测”和“加入双阶段验证后的完整方法”之间的性能差异，结果如表 5.4 所示。

表 5.4　双阶段验证机制有效性分析

方法版本	Precision	Recall	F1	False Positive Rate
无双阶段验证	[填写]	[填写]	[填写]	[填写]
加入双阶段验证	**[填写]**	[填写]	**[填写]**	**[填写]**

由表 5.4 可见，引入双阶段验证后，Precision 和 F1 值均有提升，误判率下降了**[填写]**。这表明双阶段验证机制能够有效过滤那些虽然具有较高差异分数、但其实由任务语义变化或生成波动造成的非偏见样本，从而缓解过度公平判断现象。

总体上看，双阶段验证机制并不是简单追求更高召回，而是在保持识别覆盖的同时提高高置信样本的纯度，这一点与本文第三章的设计目标是一致的。

5.4.3 不同模型上的识别性能分析

为验证本文方法的模型通用性，本文进一步在不同目标模型上进行偏见识别实验，结果如表 5.5 所示。

表 5.5　不同目标模型上的偏见识别效果比较

目标模型	Accuracy	F1	False Positive Rate
Qwen-2.5-14B-Instruct	[填写]	[填写]	[填写]
Llama-3.1-8B-Instruct	[填写]	[填写]	[填写]
GPT-4o	[填写]	[填写]	[填写]

实验结果表明，本文方法在开源本地模型和闭源 API 模型上均取得了稳定表现，说明其核心机制主要依赖输入输出层面的反事实比较与验证，而不是依赖特定模型内部结构。因此，该方法具有较好的黑盒适用性和模型迁移能力。

5.4.4 典型案例分析

为了直观展示第三章方法的识别过程，本文选取若干典型案例进行分析。对于每个案例，分别展示原始输入、反事实输入、原始回复与反事实回复、偏见敏感性分数以及双阶段验证结果。通过案例分析可以发现，本文方法不仅能够捕获显式群体偏见，

也能够识别那些表面措辞温和、但在建议倾向和资源分配上体现差别对待的隐式偏见回复。

图 **??** 可用于展示典型识别案例的对齐与验证结果。

5.5 偏见校正实验结果与分析

5.5.1 偏见校正总体效果比较

表 5.6 给出了不同方法在偏见校正任务上的总体效果比较。本文重点从偏见消除率、反事实一致性改善、信息保留度、语义相似度、流畅度、编辑距离比例和平均推理延迟等维度进行对比。

表 5.6　偏见校正阶段总体效果比较

方法	BER	FCI	Preserve	Sim/BERTScore	Fluency	EditRatio	Latency
Raw LLM	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
Direct Refusal	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
Self-Debias	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
Constitutional Rewriting	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
Full Rewrite	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
Random Priority Rewrite	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]	[填写]
本文方法	**[填写]**	**[填写]**	**[填写]**	**[填写]**	**[填写]**	**[填写]**	[填写]

由表 5.6 可见，本文方法在偏见校正阶段取得了较好的综合表现。具体而言，偏见消除率达到 **[填写]**，反事实一致性提升 **[填写]**，信息保留度达到 **[填写]**，语义相似度达到 **[填写]**，流畅度评分达到 **[填写]**，平均编辑距离比例控制在 **[填写]**。这一结果表明，本文方法不仅能够有效降低偏见风险，而且能够在较小改动范围内保持原始回复的主要信息和自然表达。

与全量重写方法相比，本文方法在 BER 接近或更高的同时，EditRatio 明显更低，说明局部定向重写能够减少不必要的文本修改。与直接拒答相比，本文方法虽然在极端安全性上未必占优，但在信息保留度和任务有用性上具有明显优势，更符合面向真实部署场景的输出后处理需求。

5.5.2 最小编辑约束重写效果分析

为了进一步验证第四章中最小编辑约束设计的作用，本文重点比较不同重写方法在修改幅度与质量保持方面的差异。图 **??** 给出了各方法在编辑距离比例和信息保留度上的对比结果。

从图中可以看出，整体重写方法虽然能够在一定程度上改善公平性，但往往需要更大幅度修改原始回复，从而导致信息保留度下降。相比之下，本文方法通过风险片段精确定位和优先级排序，将修改范围集中在高风险局部区域，因此在维持较高偏见消除率的同时，将编辑距离比例控制在较低水平。这说明最小编辑约束确实能够提升局部重写策略在文本质量保持方面的表现。

5.5.3 公平性与文本质量权衡分析

由于偏见校正本质上是一个公平性改善与文本质量保持之间的多目标平衡问题，本文进一步采用帕累托前沿的方式对不同方法进行比较。图 **??** 以偏见消除率为纵轴、信息保留度为横轴，展示了各方法在公平性与质量权衡上的位置关系。

实验结果表明，本文方法整体位于更优的权衡区域，即在不显著损害文本质量的前提下实现了更高的公平性改善。这说明代价感知优先级排序、最小编辑约束和一致性校验等机制能够协同发挥作用，使校正过程更符合实际应用场景中的多目标要求。

5.5.4 典型案例分析

为了进一步展示本文方法的具体校正行为，本文选取若干典型案例进行分析，分别展示原始回复、定位出的高风险片段、重写后回复以及对应的公平性改善和质量保持情况。通过案例分析可以发现，本文方法倾向于对带有群体刻板印象、差别性建议或不当归纳的局部表达进行针对性修正，而对原始回复中的事实描述和任务主旨保持较高程度的保留。

图 **??** 可用于展示代表性偏见校正案例。

5.6 消融实验与参数敏感性分析

5.6.1 去除双阶段验证的影响

为了分析双阶段验证在识别阶段的作用，本文比较“仅使用反事实差异检测”和“反事实差异检测 + 双阶段验证”两种设置下的实验结果。消融结果表明，去除双阶段

验证后，虽然部分样本的召回有所提升，但误判率明显增大，最终导致 F1 值下降。这说明双阶段验证模块对于提高偏见确认的稳定性和减少过度公平判断具有关键作用。

5.6.2 去除优先级排序的影响

为了分析代价感知优先级排序的作用，本文进一步比较“随机顺序重写”和“基于优先级排序的重写”两种方式。实验结果表明，缺少优先级排序时，方法容易将改写资源分配到风险较低但编辑代价较高的片段上，从而在整体偏见消除率、信息保留度和编辑距离比例等指标上均出现退化。这说明优先级排序机制能够有效提高局部重写的效率和针对性。

5.6.3 去除最小编辑约束的影响

为分析最小编辑约束的重要性，本文将完整方法与不施加最小编辑约束的宽松重写策略进行比较。结果表明，去除该约束后，虽然部分样本的偏见风险可以进一步降低，但编辑距离比例显著增大，语义相似度和信息保留度下降，说明过于自由的重写会导致不必要的语义漂移。因此，最小编辑约束是实现公平性改善与文本质量保持平衡的关键条件之一。

5.6.4 去除一致性校验的影响

本文进一步去除一致性校验模块，直接接受所有重写结果。实验发现，在缺少一致性校验时，部分校正结果虽然降低了原有偏见表达，但同时引入了新的有害内容、语义不连贯问题或模板化拒答，从而使整体文本质量下降。这说明一致性校验机制对于控制校正后副作用、提升结果稳健性具有重要作用。

5.6.5 关键参数敏感性分析

最后，本文对若干关键参数进行敏感性分析，包括偏见敏感性评分中各差异维度的权重系数、候选样本初筛阈值、优先级函数中的权重系数以及重写阶段的编辑预算上限。图 **??** 可用于展示主要参数变化对偏见识别和偏见校正结果的影响趋势。

总体来看，本文方法在合理参数区间内表现较为稳定，但不同场景下最优参数配置仍存在差异。因此，在实际部署中可根据公平性目标和计算预算对参数进行适当调整。

5.7 本章小结

本章围绕第三章和第四章提出的方法设计了系统实验，并构建了面向黑盒大语言模型输出后处理的综合评价框架，从公平性、文本质量和效率代价三个层面对方法进行了统一评估。实验结果表明，本文提出的反事实构造与双阶段验证方法能够有效提升偏见识别的准确性与稳健性，代价感知与最小编辑约束重写方法能够在降低偏见风险的同时较好保持原始回复的信息内容与语义质量。进一步的消融实验和参数敏感性分析也验证了各关键模块在整体方法中的必要性与有效性。

结论

本文采用……（结论作为学位论文正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。）

参考文献

[1] Brown T B, Mann B, Ryder N, et al. Language Models are Few-Shot Learners[C]. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020.

[2] Bommasani R, Hudson D A, Adeli E, et al. On the Opportunities and Risks of Foundation Models[J]. CoRR, 2021, abs/2108.07258.

[3] Kojima T, Gu S S, Reid M, et al. Large Language Models are Zero-Shot Reasoners[C]. Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022. 2022.

[4] Gallegos I O, Rossi R A, Barrow J, et al. Bias and Fairness in Large Language Models: A Survey[J]. Comput. Linguistics, 2024, 50(3): 1097-1179.

[5] Bender E M, Gebru T, McMillan-Major A, et al. On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?[C]. FAccT ’21: 2021 ACM Conference on Fairness, Accountability, and Transparency, Virtual Event / Toronto, Canada, March 3-10, 2021. ACM, 2021: 610-623.

[6] Dodge J, Sap M, Marasovic A, et al. Documenting Large Webtext Corpora: A Case Study on the Colossal Clean Crawled Corpus[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021. Association for Computational Linguistics, 2021: 1286-1305.

[7] Sheng E, Chang K, Natarajan P, et al. Societal Biases in Language Generation: Progress and Challenges [C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, ACL/IJCNLP 2021, (Volume 1: Long Papers), Virtual Event, August 1-6, 2021. Association for Computational Linguistics, 2021: 4275-4293.

[8] Ferrara E. Should ChatGPT be biased? Challenges and risks of bias in large language models[J]. First Monday, 2023, 28(11).

[9] Islam A C, Bryson J J, Narayanan A. Semantics derived automatically from language corpora necessarily contain human biases[J]. CoRR, 2016, abs/1608.07187.

[10] May C, Wang A, Bordia S, et al. On Measuring Social Biases in Sentence Encoders[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 2-7, 2019, Volume 1 (Long and Short Papers). Association for Computational Linguistics, 2019: 622-628.

[11] Tan Y C, Celis L E. Assessing Social and Intersectional Biases in Contextualized Word Representations[C]. Advances in Neural Information Processing Systems 32: Annual Conference on Neural Information Processing Systems 2019, NeurIPS 2019, December 8-14, 2019, Vancouver, BC, Canada. 2019: 13209-13220.

[12] Guo W, Caliskan A. Detecting Emergent Intersectional Biases: Contextualized Word Embeddings Contain a Distribution of Human-like Biases[C]. AIES '21: AAAI/ACM Conference on AI, Ethics, and Society, Virtual Event, USA, May 19-21, 2021. ACM, 2021: 122-133.

[13] Dolci T, Azzalini F, Tanelli M. Improving Gender-Related Fairness in Sentence Encoders: A Semantics-Based Approach[J]. Data Sci. Eng., 2023, 8(2): 177-195.

[14] Goldfarb-Tarrant S, Marchant R, Sánchez R M, et al. Intrinsic Bias Metrics Do Not Correlate with Application Bias[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, ACL/IJCNLP 2021, (Volume 1: Long Papers), Virtual Event, August 1-6, 2021. Association for Computational Linguistics, 2021: 1926-1940.

[15] Delobelle P, Tokpo E K, Calders T, et al. Measuring Fairness with Biased Rulers: A Comparative Study on Bias Metrics for Pre-trained Language Models[C]. Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL 2022, Seattle, WA, United States, July 10-15, 2022. Association for Computational Linguistics, 2022: 1693-1706.

[16] Cabello L, Jørgensen A K, Søgaard A. On the Independence of Association Bias and Empirical Fairness in Language Models[C]. Proceedings of the 2023 ACM Conference on Fairness, Accountability, and Transparency, FAccT 2023, Chicago, IL, USA, June 12-15, 2023. ACM, 2023: 370-378.

[17] Kurita K, Vyas N, Pareek A, et al. Measuring Bias in Contextualized Word Representations[J]. CoRR, 2019, abs/1906.07337.

[18] Webster K, Wang X, Tenney I, et al. Measuring and Reducing Gendered Correlations in Pre-trained Models[J]. CoRR, 2020, abs/2010.06032.

[19] Ahn J, Oh A. Mitigating Language-Dependent Ethnic Bias in BERT[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021. Association for Computational Linguistics, 2021: 533-549.

[20] Nangia N, Vania C, Bhalerao R, et al. CrowS-Pairs: A Challenge Dataset for Measuring Social Biases in Masked Language Models[C]. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020. Association for Computational Linguistics, 2020: 1953-1967.

[21] Nadeem M, Bethke A, Reddy S. StereoSet: Measuring stereotypical bias in pretrained language models[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, ACL/IJCNLP 2021, (Volume 1: Long Papers), Virtual Event, August 1-6, 2021. Association for Computational Linguistics, 2021: 5356-5371.

[22] Kaneko M, Bollegala D. Unmasking the Mask - Evaluating Social Biases in Masked Language Models[C]. Thirty-Sixth AAAI Conference on Artificial Intelligence, AAAI 2022, Thirty-Fourth Conference on Innovative Applications of Artificial Intelligence, IAAI 2022, The Twelveth Symposium on Educational Advances in Artificial Intelligence, EAAI 2022 Virtual Event, February 22 - March 1, 2022. AAAI Press, 2022: 11954-11962.

[23] Barikeri S, Lauscher A, Vulic I, et al. RedditBias: A Real-World Resource for Bias Evaluation and Debiasing of Conversational Language Models[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, ACL/IJCNLP 2021, (Volume 1: Long Papers), Virtual Event, August 1-6, 2021. Association for Computational Linguistics, 2021: 1941-1955.

[24] Blodgett S L, Lopez G, andRobert Sim A O, et al. Stereotyping Norwegian Salmon: An Inventory of Pitfalls in Fairness Benchmark Datasets[C]. Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, ACL/IJCNLP 2021, (Volume 1: Long Papers), Virtual Event, August 1-6, 2021. Association for Computational Linguistics, 2021: 1004-1015.

[25] Delobelle P, Berendt B. FairDistillation: Mitigating Stereotyping in Language Models[C]. Lecture Notes in Computer Science: Machine Learning and Knowledge Discovery in Databases - European Conference, ECML PKDD 2022, Grenoble, France, September 19-23, 2022, Proceedings, Part II. Springer, 2022: 638-654.

[26] Kaneko M, Bollegala D, Okazaki N. Debiasing Isn't Enough! - on the Effectiveness of Debiasing MLMs and Their Social Biases in Downstream Tasks[C]. Proceedings of the 29th International Conference on Computational Linguistics, COLING 2022, Gyeongju, Republic of Korea, October 12-17, 2022. International Committee on Computational Linguistics, 2022: 1299-1310.

[27] Sheng E, Chang K, Natarajan P, et al. The Woman Worked as a Babysitter: On Biases in Language Generation[C]. Inui K, Jiang J, Ng V, et al. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, EMNLP-IJCNLP 2019, Hong Kong, China, November 3-7, 2019. Association for Computational Linguistics, 2019: 3405-3410.

[28] Gehman S, Gururangan S, Sap M, et al. RealToxicityPrompts: Evaluating Neural Toxic Degeneration

in Language Models[C]. Findings of ACL: Findings of the Association for Computational Linguistics: EMNLP 2020, Online Event, 16-20 November 2020. Association for Computational Linguistics, 2020: 3356-3369.

[29] Dhamala J, Sun T, Kumar V, et al. BOLD: Dataset and Metrics for Measuring Biases in Open-Ended Language Generation[C]. FAccT '21: 2021 ACM Conference on Fairness, Accountability, and Transparency, Virtual Event / Toronto, Canada, March 3-10, 2021. ACM, 2021: 862-872.

[30] Nozza D, Bianchi F, Hovy D. HONEST: Measuring Hurtful Sentence Completion in Language Models[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2021, Online, June 6-11, 2021. Association for Computational Linguistics, 2021: 2398-2406.

[31] Sicilia A, Alikhani M. Learning to Generate Equitable Text in Dialogue from Biased Training Data [C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 2898-2917.

[32] Huang P, Zhang H, Jiang R, et al. Reducing Sentiment Bias in Language Models via Counterfactual Evaluation[C]. Findings of ACL: Findings of the Association for Computational Linguistics: EMNLP 2020, Online Event, 16-20 November 2020. Association for Computational Linguistics, 2020: 65-83.

[33] Smith E M, Hall M, Kambadur M, et al. "I'm sorry to hear that": Finding New Biases in Language Models with a Holistic Descriptor Dataset[C]. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022. Association for Computational Linguistics, 2022: 9180-9211.

[34] Parrish A, Chen A, Nangia N, et al. BBQ: A hand-built bias benchmark for question answering[C]. Findings of ACL: Findings of the Association for Computational Linguistics: ACL 2022, Dublin, Ireland, May 22-27, 2022. Association for Computational Linguistics, 2022: 2086-2105.

[35] Li T, Khot T, Khashabi D, et al. UnQovering Stereotyping Biases via Underspecified Questions[J]. CoRR, 2020, abs/2010.02428.

[36] Krieg K, Parada-Cabaleiro E, Medicus G, et al. Grep-BiasIR: A Dataset for Investigating Gender Representation Bias in Information Retrieval Results[C]. Proceedings of the 2023 Conference on Human Information Interaction and Retrieval, CHIIR 2023, Austin, TX, USA, March 19-23, 2023. ACM, 2023: 444-448.

[37] Rudinger R, Naradowsky J, Leonard B, et al. Gender Bias in Coreference Resolution[C]. Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT, New Orleans, Louisiana, USA, June 1-6, 2018, Volume 2 (Short Papers). Association for Computational Linguistics, 2018: 8-14.

[38] Zhao J, Wang T, Yatskar M, et al. Gender Bias in Coreference Resolution: Evaluation and Debiasing Methods[C]. Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT, New Orleans, Louisiana, USA, June 1-6, 2018, Volume 2 (Short Papers). Association for Computational Linguistics, 2018: 15-20.

[39] Vanmassenhove E, Emmery C, Shterionov D. NeuTral Rewriter: A Rule-Based and Neural Approach to Automatic Rewriting into Gender Neutral Alternatives[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 7-11 November, 2021. Association for Computational Linguistics, 2021: 8940-8948.

[40] Webster K, Recasens M, Axelrod V, et al. Mind the GAP: A Balanced Corpus of Gendered Ambiguous Pronouns[J]. Trans. Assoc. Comput. Linguistics, 2018, 6: 605-617.

[41] Levy S, Lazar K, Stanovsky G. Collecting a Large-Scale Gender Bias Dataset for Coreference Resolution and Machine Translation[C]. Findings of ACL: Findings of the Association for Computational Linguistics: EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 16-20 November, 2021. Association for Computational Linguistics, 2021: 2470-2480.

[42] Felkner V K, Chang H H, Jang E, et al. WinoQueer: A Community-in-the-Loop Benchmark for Anti-LGBTQ+ Bias in Large Language Models[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 9126-9140.

[43] Qian R, Ross C, Fernandes J, et al. Perturbation Augmentation for Fairer NLP[C]. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022. Association for Computational Linguistics, 2022: 9496-9521.

[44] Dev S, Li T, Phillips J M, et al. On Measuring and Mitigating Biased Inferences of Word Embeddings [C]. The Thirty-Fourth AAAI Conference on Artificial Intelligence, AAAI 2020, The Thirty-Second Innovative Applications of Artificial Intelligence Conference, IAAI 2020, The Tenth AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2020, New York, NY, USA, February 7-12, 2020. AAAI Press, 2020: 7659-7666.

[45] Dwork C, Hardt M, Pitassi T, et al. Fairness through awareness[C]. Innovations in Theoretical Computer Science 2012, Cambridge, MA, USA, January 8-10, 2012. ACM, 2012: 214-226.

[46] Mehrabi N, Morstatter F, Saxena N, et al. A Survey on Bias and Fairness in Machine Learning[J]. ACM Comput. Surv., 2022, 54(6): 115:1-115:35.

[47] Selvam N R, Dev S, Khashabi D, et al. The Tail Wagging the Dog: Dataset Construction Biases of

Social Bias Benchmarks[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 1373-1386.

[48] Lu K, Mardziel P, Wu F, et al. Gender Bias in Neural Natural Language Processing[C]. Lecture Notes in Computer Science: Logic, Language, and Security - Essays Dedicated to Andre Scedrov on the Occasion of His 65th Birthday. Springer, 2020: 189-202.

[49] Maudslay R H, Gonen H, Cotterell R, et al. It's All in the Name: Mitigating Gender Bias with Name-Based Counterfactual Data Substitution[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing, EMNLP-IJCNLP 2019, Hong Kong, China, November 3-7, 2019. Association for Computational Linguistics, 2019: 5266-5274.

[50] Ghanbarzadeh S, Huang Y, Palangi H, et al. Gender-tuning: Empowering Fine-tuning for Debiasing Pre-trained Language Models[C]. Findings of ACL: Findings of the Association for Computational Linguistics: ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 5448-5458.

[51] Dixon L, Li J, Sorensen J, et al. Measuring and Mitigating Unintended Bias in Text Classification [C]. Proceedings of the 2018 AAAI/ACM Conference on AI, Ethics, and Society, AIES 2018, New Orleans, LA, USA, February 02-03, 2018. ACM, 2018: 67-73.

[52] Garimella A, Mihalcea R, Amarnath A. Demographic-Aware Language Model Fine-tuning as a Bias Mitigation Technique[C]. Proceedings of the 2nd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 12th International Joint Conference on Natural Language Processing, AACL/IJCNLP 2022 - Volume 2: Short Papers, Online only, November 20-23, 2022. Association for Computational Linguistics, 2022: 311-319.

[53] Borchers C, Gala D S, Gilburt B, et al. Looking for a Handsome Carpenter! Debiasing GPT-3 Job Advertisements[J]. CoRR, 2022, abs/2205.11374.

[54] Thakur H, Jain A, Vaddamanu P, et al. Language Models Get a Gender Makeover: Mitigating Gender Bias with Few-Shot Data Interventions[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 340-351.

[55] Ngo H, Raterink C, Araújo J G M, et al. Mitigating harm in language models with conditional-likelihood filtration[J]. CoRR, 2021, abs/2108.07790.

[56] Sattigeri P, Ghosh S, Padhi I, et al. Fair Infinitesimal Jackknife: Mitigating the Influence of Biased Training Data Points Without Refitting[C]. Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans,

LA, USA, November 28 - December 9, 2022. 2022.

[57] Dinan E, Fan A, Williams A, et al. Queens are Powerful too: Mitigating Gender Bias in Dialogue Generation[C]. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020. Association for Computational Linguistics, 2020: 8173-8188.

[58] Solaiman I, Dennison C. Process for Adapting Language Models to Society (PALMS) with Values-Targeted Datasets[C]. Advances in Neural Information Processing Systems 34: Annual Conference on Neural Information Processing Systems 2021, NeurIPS 2021, December 6-14, 2021, virtual. 2021: 5861-5873.

[59] Kim H, Yu Y, Jiang L, et al. ProsocialDialog: A Prosocial Backbone for Conversational Agents[C]. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022. Association for Computational Linguistics, 2022: 4005-4029.

[60] Ung M, Xu J, Boureau Y. SaFeRDialogues: Taking Feedback Gracefully after Conversational Safety Failures[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin, Ireland, May 22-27, 2022. Association for Computational Linguistics, 2022: 6462-6481.

[61] Sun H, Zhang Z, Mi F, et al. MoralDial: A Framework to Train and Evaluate Moral Dialogue Systems via Moral Discussions[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 2213-2230.

[62] Mattern J, Jin Z, Sachan M, et al. Understanding Stereotypes in Language Models: Towards Robust Measurement and Zero-Shot Debiasing[J]. CoRR, 2022, abs/2212.10678.

[63] Venkit P N, Gautam S, Panchanadikar R, et al. Nationality Bias in Text Generation[C]. Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics, EACL 2023, Dubrovnik, Croatia, May 2-6, 2023. Association for Computational Linguistics, 2023: 116-122.

[64] Abid A, Farooqi M, Zou J. Persistent Anti-Muslim Bias in Large Language Models[C]. AIES ’21: AAAI/ACM Conference on AI, Ethics, and Society, Virtual Event, USA, May 19-21, 2021. ACM, 2021: 298-306.

[65] Fatemi Z, Xing C, Liu W, et al. Improving Gender Fairness of Pre-Trained Language Models without Catastrophic Forgetting[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 1249-1262.

[66] Kumar S, Balachandran V, Njoo L, et al. Language Generation Models Can Cause Harm: So What Can We Do About It? An Actionable Survey[C]. Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics, EACL 2023, Dubrovnik, Croatia, May 2-6, 2023. Association for Computational Linguistics, 2023: 3291-3313.

[67] Devinney H, Björklund J, Björklund H. Theories of ”Gender” in NLP Bias Research[C]. FAccT ’22: 2022 ACM Conference on Fairness, Accountability, and Transparency, Seoul, Republic of Korea, June 21 - 24, 2022. ACM, 2022: 2083-2102.

[68] Bordia S, Bowman S R. Identifying and Reducing Gender Bias in Word-Level Language Models[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2019, Minneapolis, MN, USA, June 3-5, 2019, Student Research Workshop. Association for Computational Linguistics, 2019: 7-15.

[69] Ravfogel S, Elazar Y, Gonen H, et al. Null It Out: Guarding Protected Attributes by Iterative Nullspace Projection[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020, Online, July 5-10, 2020. Association for Computational Linguistics, 2020: 7237-7256.

[70] Liang P P, Li I M, Zheng E, et al. Towards Debiasing Sentence Representations[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, ACL 2020, Online, July 5-10, 2020. Association for Computational Linguistics, 2020: 5502-5515.

[71] Woo T, Nam W, Ju Y, et al. Compensatory Debiasing For Gender Imbalances In Language Models[C]. IEEE International Conference on Acoustics, Speech and Signal Processing ICASSP 2023, Rhodes Island, Greece, June 4-10, 2023. IEEE, 2023: 1-5.

[72] Guo Y, Yang Y, Abbasi A. Auto-Debias: Debiasing Masked Language Models with Automated Biased Prompts[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2022, Dublin, Ireland, May 22-27, 2022. Association for Computational Linguistics, 2022: 1012-1023.

[73] Gaci Y, Benatallah B, Casati F, et al. Debiasing Pretrained Text Encoders by Paying Attention to Paying Attention[C]. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022. Association for Computational Linguistics, 2022: 9582-9602.

[74] Zheng C, Ke P, Zhang Z, et al. Click: Controllable Text Generation with Sequence Likelihood Contrastive Learning[C]. Findings of ACL: Findings of the Association for Computational Linguistics: ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 1022-1040.

[75] Jin X, Barbieri F, Kennedy B, et al. On Transferability of Bias Mitigation Effects in Language Model

Fine-Tuning[C]. Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, NAACL-HLT 2021, Online, June 6-11, 2021. Association for Computational Linguistics, 2021: 3770-3783.

[76] Xu J, Ju D, Li M, et al. Recipes for Safety in Open-domain Chatbots[J]. CoRR, 2020, abs/2010.07079.

[77] Shuster K, Xu J, Komeili M, et al. BlenderBot 3: a deployed conversational agent that continually learns to responsibly engage[J]. CoRR, 2022, abs/2208.03188.

[78] Schramowski P, Turan C, Andersen N, et al. Large pre-trained language models contain human-like biases of what is right and wrong to do[J]. Nat. Mach. Intell., 2022, 4(3): 258-268.

[79] Saunders D, Sallis R, Byrne B. First the Worst: Finding Better Gender Translations During Beam Search[C]. Findings of the Association for Computational Linguistics: ACL 2022, Dublin, Ireland, May 22-27, 2022. Association for Computational Linguistics, 2022: 3814-3823.

[80] Meade N, Gella S, Hazarika D, et al. Using In-Context Learning to Improve Dialogue Safety[C]. Findings of the Association for Computational Linguistics: EMNLP 2023, Singapore, December 6-10, 2023. Association for Computational Linguistics, 2023: 11882-11910.

[81] Krause B, Gotmare A D, McCann B, et al. GeDi: Generative Discriminator Guided Sequence Generation[C]. Findings of the Association for Computational Linguistics: EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 16-20 November, 2021. Association for Computational Linguistics, 2021: 4929-4952.

[82] Liu X, Khalifa M, Wang L. BOLT: Fast Energy-based Controlled Text Generation with Tunable Biases[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 186-200.

[83] Zayed A, Mordido G, Shabanian S, et al. Should We Attend More or Less? Modulating Attention for Fairness[J]. CoRR, 2023, abs/2305.13088.

[84] Hauzenberger L, Masoudian S, Kumar D, et al. Modular and On-demand Bias Mitigation with Attribute-Removal Subnetworks[C]. Findings of the Association for Computational Linguistics: ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 6192-6214.

[85] Pryzant R, Martinez R D, Dass N, et al. Automatically Neutralizing Subjective Bias in Text[C]. The Thirty-Fourth AAAI Conference on Artificial Intelligence, AAAI 2020, The Thirty-Second Innovative Applications of Artificial Intelligence Conference, IAAI 2020, The Tenth AAAI Symposium on Educational Advances in Artificial Intelligence, EAAI 2020, New York, NY, USA, February 7-12, 2020. AAAI Press, 2020: 480-489.

[86] Ma X, Sap M, Rashkin H, et al. PowerTransformer: Unsupervised Controllable Revision for Biased Language Correction[C]. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing, EMNLP 2020, Online, November 16-20, 2020. Association for Computational Linguistics, 2020: 7426-7441.

[87] He Z, Majumder B P, McAuley J J. Detect and Perturb: Neutral Rewriting of Biased and Sensitive Text via Gradient-based Decoding[C]. Findings of the Association for Computational Linguistics: EMNLP 2021, Virtual Event / Punta Cana, Dominican Republic, 16-20 November, 2021. Association for Computational Linguistics, 2021: 4173-4181.

[88] Dhingra H, Jayashanker P, Moghe S, et al. Queer People are People First: Deconstructing Sexual Identity Stereotypes in Large Language Models[J]. CoRR, 2023, abs/2307.00101.

[89] Amrhein C, Schottmann F, Sennrich R, et al. Exploiting Biased Models to De-bias Text: A Gender-Fair Rewriting Model[C]. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), ACL 2023, Toronto, Canada, July 9-14, 2023. Association for Computational Linguistics, 2023: 4486-4506.

[90] Majumder B P, He Z, McAuley J J. InterFair: Debiasing with Natural Language Feedback for Fair Interpretable Predictions[C]. Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023. Association for Computational Linguistics, 2023: 9466-9471.

[91] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems: vol. 30. 2017.

[92] OpenAI, Achiam J, Adler S, et al. GPT-4 Technical Report[J]. arXiv preprint arXiv:2303.08774, 2023.

[93] Grattafiori A, Dubey A, Jauhri A, et al. The Llama 3 Herd of Models[J]. arXiv preprint arXiv:2407.21783, 2024.

[94] Liang P, Bommasani R, Lee T, et al. Holistic Evaluation of Language Models[J]. arXiv preprint arXiv:2211.09110, 2022.

[95] Kusner M J, Loftus J R, Russell C, et al. Counterfactual Fairness[C]. Advances in Neural Information Processing Systems: vol. 30. 2017.

[96] Blodgett S L, Barocas S, Daumé III H, et al. Language (Technology) Is Power: A Critical Survey of ”Bias” in NLP[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020: 5454-5476.

[97] Chu Z, Wang Z, Zhang W. Fairness in Large Language Models: A Taxonomic Survey[J]. SIGKDD Explorations, 2024, 26(1): 34-48.

[98] Lan T, Li J, Wang Y, et al. F^2Bench: An Open-ended Fairness Evaluation Benchmark for LLMs with Factuality Considerations[C]. Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, EMNLP 2025, Suzhou, China, November 4-9, 2025. Association for Computational Linguistics, 2025: 2031-2046.

[99] Wang S, Wang P, Zhou T, et al. CEB: Compositional Evaluation Benchmark for Fairness in Large Language Models[J]. arXiv preprint arXiv:2407.02408, 2024.

[100] Hartvigsen T, Gabriel S, Palangi H, et al. ToxiGen: A Large-Scale Machine-Generated Dataset for Adversarial and Implicit Hate Speech Detection[C]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics. 2022: 3309-3326.

[101] Gallegos I O, Rossi R A, Barrow J, et al. Self-Debiasing Large Language Models: Zero-Shot Recognition and Reduction of Stereotypes[C]. Proceedings of the 2025 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. 2025.

[102] Bai Y, Kadavath S, Kundu S, et al. Constitutional AI: Harmlessness from AI Feedback[J]. arXiv preprint arXiv:2212.08073, 2022.

攻读学位期间发表论文与研究成果清单

[1] Doe J, **Zhang S**. The Book with Title[M]. Dummy Publisher, 2000. (已出版.).

[2] 张三, 李杰, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2006(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.).

[3] 李杰, 张三, 罗运军. 交联型与线形水性聚氨酯的形状记忆性能比较[J]. 化工进展, 2007(01): 78-81. (EI 收录, 检索号:06129773469. 已刊出.).

[4] **Zhang S**. The Book without Title[M]. Dummy Publisher, 2100. (已出版.).