研究内容一：基于反事实替代检测的大语言模型输出偏见识别方法

1. 敏感属性提取反事实 prompt 构造

2. 原始回复与反事实回复差异检测

2.1 输入与输出

输入为原始 prompt x、其反事实集合 $X^{cf}(x)=\{x_1',x_2',\dots,x_m'\}$，以及目标大语言模型生成的原始回复 y 和反事实回复集合 $\{y_1',y_2',\dots,y_m'\}$。输出为单个样本的偏见敏感性分数

$$S_{\text{sens}}(x)=\alpha D_{\text{sem}}(x)+\beta D_{\text{att}}(x)+\gamma D_{\text{ppl}}(x)$$

其中 $\alpha+\beta+\gamma=1$，三项分数在融合前统一归一化到 $[0,1]$。

2.2 回复生成与对齐预处理

对原始 prompt 和每个反事实 prompt，在**相同模型、相同系统提示、相同解码参数**下生成回复，尽量控制除敏感属性外的其他变量不变。随后进行三步预处理：

1. 去除格式性噪声，如多余空格、模板前缀、免责声明重复句。
2. 将原始回复 y 与每个 y_i' 做句子级切分，保留正文内容。
3. 对长度差异过大的回复做标记，防止后续分数被异常冗长或异常简短文本主导。

这一步的目的，是保证后续三类差异度量尽可能反映“敏感属性替换造成的变化”，而不是采样噪声或模板噪声。

2.3 语义偏移度计算

这一部分直接借鉴 MEDEQUALQA 的核心思想。该论文在 pronoun counterfactual 审计中，将不同人口属性版本下生成的 reasoning trace 编码为 sentence-transformer 向量，并以 cosine similarity 计算 STS，用于衡量推理路径的稳定性；其结果表明，即便整体 STS 较高，局部仍可能出现风险因素、依据或排序上的变化，因此 STS适合做全局语义稳定性刻画。

因此，你的语义偏移度可定义为：

$$D_{\text{sem}}(x)=\frac{1}{m}\sum_{i=1}^{m}\left(1-\cos\big(\phi(y),\phi(y_i')\big)\right)$$

其中 $\phi(\cdot)$ 表示 sentence-transformer 编码器，$\cos(\cdot,\cdot)$ 为余弦相似度。

这里采用 $1-\text{cosine}$ 而不是直接用 STS，是为了让数值含义更统一：**值越大，表示语义偏移越明显**。
在实现上，可以再补一个句子级局部偏移辅助量：

$$D_{\text{local}}(x)=\max_j \left(1-\cos(\phi(s_j),\phi(s'_{i,j^*}))\right)$$

但这个局部量更适合后面的片段定位模块，在本模块中可以只把它作为辅助记录，不必并入主分数。

2.4 态度变化计算

态度变化反映的是：在敏感属性替换前后，模型对同一对象的情绪取向、褒贬程度或推荐倾向是否发生变化。这里可以调用 `distilbert/distilbert-base-uncased-finetuned-sst-2-english`，对原始回复和反事实回复分别输出正向/负向情感概率。

设模型对文本 z 的输出为：

$$p_{\text{pos}}(z),\quad p_{\text{neg}}(z)$$

定义其态度分数为

$$a(z)=p_{\text{pos}}(z)-p_{\text{neg}}(z)$$

则 $a(z)\in[-1,1]$。当 $a(z)$ 越大，说明回复越正向；越小则越负向。

于是态度变化可写为：

$$D_{\text{att}}(x)=\frac{1}{m}\sum_{i=1}^{m}\frac{|a(y)-a(y_i')|}{2}$$

这里除以 2 是为了将该项归一到 $[0,1]$。

这样定义有两个优点。第一，它比只看“正类概率”更稳，因为把正负两类同时纳入。第二，它更适合你的公平性场景：同一句建议、评价、推荐，如果只是因为“她”变成“他”就明显更正面或更负面，那么该差异会被直接放大。

2.5 困惑度差异计算

这一部分应当明确说明：**TWBias 原文并不是做开放式回复两两比较，而是对替换后的偏见句进行概率式评估，并且只在 response 部分计算 PPL，再通过 t 检验和 Cohen’s d 衡量群体差异。** 也就是说，你这里不能机械照搬它的统计检验流程，但可以借用其两个很关键的思想：
第一，PPL 应只在回复部分计算；
第二，PPL 计算应放在统一的 chat template 下进行，以贴近真实使用场景。

TWBias 的 response-only PPL 定义为：

$$\mathrm{PPL}(X,l)=\exp\left\{-\frac{1}{t-l}\sum_{k=l+1}^{t}\log p_{\theta}(x_k\mid x_{<k})\right\}$$

其中 $X=[X^P;X^R]$ 为“提示部分 + 回复部分”的拼接序列，l 为 prompt 部分长度，只对 response 部分 X^R 的 token 计算困惑度。

迁移到你的场景后，可将原始回复和反事实回复分别包入同一聊天模板，得到：

$$X=[X^P;X^R],\qquad X_i'=[X_i^{P};X_i^{R}]$$

然后分别计算：

$$\mathrm{PPL}_{\text{resp}}(y),\qquad \mathrm{PPL}_{\text{resp}}(y_i')$$

由于 PPL 本身量纲波动较大，直接做差容易不稳定，更稳妥的方式是比较对数困惑度：

$$D_{\text{ppl}}(x)=\frac{1}{m}\sum_{i=1}^{m} \frac{\left|\log \mathrm{PPL}_{\text{resp}}(y)-\log \mathrm{PPL}_{\text{resp}}(y_i')\right|}{Z}$$

其中 Z 是归一化常数，可以取开发集上的最大值、分位数，或用 min-max 标准化得到最终 [0,1] 分数。

这一项的含义是：当敏感属性替换后，模型对回复文本的“生成自然度”或“概率偏好”发生显著变化时，说明模型内部对两类群体表述存在不同的语言偏置。与语义偏移和态度变化相比，PPL 差异更像是一个**模型偏好层面的隐式信号**。

2.6 三分量归一化与融合

三项分数得到后，分别做归一化：

$$\hat D_{\text{sem}},\ \hat D_{\text{att}},\ \hat D_{\text{ppl}}\in[0,1]$$

再计算：

$$S_{\text{sens}}(x)=\alpha \hat D_{\text{sem}}(x)+\beta \hat D_{\text{att}}(x)+\gamma \hat D_{\text{ppl}}(x)$$

权重可按以下思路设置：

- 若更强调“内容层面的反事实稳定性”，可提高 α；
- 若更关注“评价态度是否双标”，可提高 β；
- 若更关注“模型对不同群体表述的隐式概率偏好”，可提高 γ。

论文初稿里可先设

$$\alpha=0.5,\quad \beta=0.3,\quad \gamma=0.2$$

后续再通过消融实验分析权重敏感性。

2.7 判定规则

对每个样本得到 $S_{\text{sens}}(x)$ 后，可设置阈值 τ_s：

$$\mathcal{C}=\{(x,y)\mid S_{\text{sens}}(x)>\tau_s\}$$

将其作为**候选偏见回复集合**输入后续二阶段验证模块。这样做的意义是，本模块只负责“高召回地发现异常差异”，而不直接最终定性为偏见；最终是否属于应修正的偏见性差异，再由后续 judge 与事实性校验完成。这个分工和你现有方案中的“双阶段验证”是匹配的。